

Gradient Flow와 Edge of Stability

최적화 이론 입문자를 위한 발표 준비 노트

Gradient descent를 연속시간 극한으로 보내 얻는 gradient flow에서 출발하여, 유한 step size가 만드는 안정성 경계 $2/\eta$ 와 neural-network training의 Edge of Stability를 연결한다. 마지막에는 Cohen et al.의 실험적 관찰과 Arora–Li–Panigrahi의 limiting-flow 해석을 같은 그림 안에서 정리한다.

Primary readings

Cohen et al., **Gradient Descent on Neural Networks Typically Occurs at the Edge of Stability**, ICLR 2021.

Arora, Li, Panigrahi, **Understanding Gradient Descent on the Edge of Stability in Deep Learning**, ICML 2022.

Contents

1	먼저 맞춰 둘 기호와 큰 그림	3
1.1	기호 대응표	3
1.2	한 장으로 보는 전체 논리	3
2	Gradient Descent에서 Gradient Flow로	5
2.1	GD를 Euler discretization으로 보기	5
2.2	왜 이름이 “flow”인가?	5
2.3	가장 중요한 identity: energy dissipation	6
2.4	PL 조건 아래에서의 지수 수렴	6
2.5	Quadratic에서 GF를 정확히 풀기	7
3	유한 step size와 $2/\eta$ 안정성 경계	8
3.1	1차원 quadratic: 모든 것이 여기서 시작한다	8
3.2	d 차원 quadratic: sharpness가 등장한다	9
3.3	GF와 GD가 curvature를 처리하는 방식의 차이	9
3.4	Descent lemma에서 나타나는 $2/\beta$ 충분조건	10
3.5	비볼록 neural loss에서는 왜 $2/\eta$ 를 넘자마자 영원히 발산하지 않는가?	10
4	Cohen et al. (2021): Edge of Stability라는 관측	12
4.1	논문이 발견한 두 단계	12
4.2	gradient flow trajectory와의 관계	12
4.3	“progressive sharpening”이 왜 EoS를 피하기 어렵게 만드는가	13
4.4	learning-rate drop 실험의 의미	13
4.5	EoS는 classical quadratic stability와 모순인가?	13
4.6	LLM/Transformer 발표에서의 안전한 해석	13
4.7	논문에서 하지 않은 주장	14
5	Arora–Li–Panigrahi (2022): EoS를 수학적으로 모델링하기	15
5.1	왜 현재점의 sharpness만으로는 부족한가?	15
5.2	EoS를 만드는 두 메커니즘	16
5.3	최소점 하나가 아니라 manifold를 본다	17
5.4	두 시간축: Phase I과 Phase II	17
5.5	limiting flow: EoS가 sharpness를 낮추는 방향으로 움직인다	18
5.6	논문의 toy loss로 직접 확인하기	19
5.7	“implicit regularization”이라는 말의 정확한 의미	20
6	Gradient Flow와 EoS를 하나의 그림으로 연결하기	21
6.1	세 가지 dynamics를 분리해서 보자	21
6.2	왜 “GF가 GD의 근사”라는 말이 EoS에서는 실패하는가	21
6.3	EoS의 period-2 구조를 local eigenmode로 읽기	22
6.4	GF endpoint와 finite-step solution selection	22
6.5	발표에서 자주 나올 질문	22
7	발표 준비용 압축 정리	24
7.1	칠판에 반드시 남길 8개 식	24

7.2 발표 순서 추천	24
7.3 혼한 실수 체크리스트	25
7.4 30초 결론	25
참고문헌 및 원문에서 확인할 위치	26

1

먼저 맞춰 들 기호와 큰 그림

1.1 기호 대응표

논문과 ODE/최적화 교재는 같은 대상을 다른 문자로 쓴다. 이 노트에서는 가능한 한 $\theta, \mathcal{L}, \eta, t$ 로 통일하되, 원 논문의 수식을 소개할 때는 원 기호를 병기한다.

개념	이 노트	ODE/수치해석 관용	Cohen et al. (2021)	Arora et al. (2022)
파라미터	θ 또는 x	$x(t)$	x_t	$x, x_\eta(t)$
목적함수/에너지	$\mathcal{L}$	$F, E, \mathcal{E}$	f	L
GD step size	η	h (Euler step)	η	η
연속시간	t	t 또는 τ	gradient-flow time t	τ
이산 iteration	k	k	t (논문 표기)	$t \in \mathbb{N}$
Hessian	$H = \nabla^2 \mathcal{L}$	$\nabla^2 F$	$\nabla^2 f$	$\nabla^2 L$
sharpness	λ_1	$\lambda_{\max}(H)$	$\lambda_{\max}(\nabla^2 f)$	$\lambda_1(\nabla^2 L)$
최소점 집합	Γ	—	—	$\Gamma = \{x : L(x) = 0\}$
GF 종착점 사상	Φ	—	—	$\Phi(x) = \lim_{\tau \rightarrow \infty} \phi(x, \tau)$

주의— 특히 L 의 중복 사용 최적화 교재에서는 “ L -smooth”의 L 이 **Lipschitz constant**를 뜻하는 경우가 많지만, Arora et al.에서는 $L(x)$ 가 **loss function** 자체다. 혼동을 피하기 위해 이 노트에서는 smoothness constant를 β 로 쓴다.

1.2 한 장으로 보는 전체 논리

1. GD는

$$\theta_{k+1} = \theta_k - \eta \nabla \mathcal{L}(\theta_k)$$

이고, $\eta \rightarrow 0$ 에서 시간을 $t = k\eta$ 로 보면 GF

$$\dot{\theta}(t) = -\nabla \mathcal{L}(\theta(t))$$

로 간다.

2. GF는 연속시간 chain rule 때문에

$$\frac{d}{dt} \mathcal{L}(\theta(t)) = -\|\nabla \mathcal{L}(\theta(t))\|^2 \leq 0$$

이다. 즉 GF 자체에는 **finite-step overshoot**가 없다.

3. 반면 GD는 1차원 quadratic에서

$$e_{k+1} = (1 - \eta\lambda)e_k$$

이므로 안정하려면 $|1 - \eta\lambda| < 1$, 즉

$$0 < \eta\lambda < 2$$

가 필요하다.

4. 신경망에서는 학습 중 sharpness λ_1 이 증가하는 **progressive sharpening**이 관측된다. 그러다가 $\lambda_1 \approx 2/\eta$ 에 도달하면 loss가 짧은 시간축에서 진동하지만 긴 시간축에서는 계속 감소한다. 이것이 Edge of Stability다.
5. Arora et al.은 특정 설정에서 이 진동이 단순한 “실패”가 아니라, 최소점 manifold 위에서 sharpness를 낮추는 느린 drift를 유도한다는 것을 보인다.

핵심 이 세미나의 핵심 대비는

Gradient Flow: infinitesimal-step dynamics,

Edge of Stability: finite-step dynamics.

이다. EoS는 GF의 작은 수정이 아니라, discretization이 본질적으로 만드는 현상이다.

발표에서 이렇게 말하기 “오늘은 GD를 연속시간으로 보내면 왜 gradient flow가 되는지부터 시작하겠습니다. Gradient flow에서는 loss가 반드시 감소합니다. 그런데 실제 finite-step GD는 Hessian의 최고유값이 $2/\eta$ 부근에 가면 전혀 다른 동역학을 보입니다. 이 두 regime 사이의 연결과 단절이 오늘 발표의 중심입니다.”

2

Gradient Descent에서 Gradient Flow로

2.1 GD를 Euler discretization으로 보기

GD의 update는

$$\theta_{k+1} = \theta_k - \eta \nabla \mathcal{L}(\theta_k). \quad (2.1)$$

양변에서 θ_k 를 빼고 η 로 나누면

$$\frac{\theta_{k+1} - \theta_k}{\eta} = -\nabla \mathcal{L}(\theta_k). \quad (2.2)$$

이제 연속시간 격자를

$$t_k = k\eta$$

로 두고 $\theta_k \approx \theta(t_k)$ 라고 생각한다. 그러면 $\eta \rightarrow 0$ 에서

$$\frac{\theta(t_k + \eta) - \theta(t_k)}{\eta} \rightarrow \frac{d\theta}{dt}(t), \quad (2.3)$$

$$-\nabla \mathcal{L}(\theta_k) \rightarrow -\nabla \mathcal{L}(\theta(t)). \quad (2.4)$$

따라서 형식적으로

$$\boxed{\dot{\theta}(t) = -\nabla \mathcal{L}(\theta(t))} \quad (2.5)$$

를 얻는다. 이것이 gradient flow다.

보충 유도 — 논문 밖의 독자용 전개 — “GD $\rightarrow$ GF”에서 실제로 쓰는 가정 위 극한은 단순히 $\eta \rightarrow 0$ 라고 쓰는 것만으로 자동으로 성립하는 것은 아니다. 예를 들어 $\nabla \mathcal{L}$ 가 국소 Lipschitz 이면 ODE의 국소 해의 존재/유일성을 확보할 수 있고, explicit Euler 방법인 GD가 유한 시간 구간에서 GF를 근사한다는 표준 수치해석 결과를 사용할 수 있다. 세미나에서는 이 정리를 증명하기보다 “GD가 GF의 explicit Euler discretization”이라는 구조를 기억하면 충분하다.

2.2 왜 이름이 “flow”인가?

초기값 x 에서 시작한 GF 해를 $\phi(x, t)$ 라고 쓰면

$$\frac{d}{dt}\phi(x, t) = -\nabla \mathcal{L}(\phi(x, t)), \quad (2.6)$$

$$\phi(x, 0) = x. \quad (2.7)$$

이를 적분형으로 쓰면

$$\phi(x, t) = x - \int_0^t \nabla \mathcal{L}(\phi(x, s)) ds. \quad (2.8)$$

Arora et al.도 이 형태를 사용하며 연속시간을 τ 로 표기한다.

2.3 가장 중요한 identity: energy dissipation

GF 위에서 loss를 시간으로 미분한다. Chain rule을 한 줄씩 적용하면

$$\frac{d}{dt}\mathcal{L}(\theta(t)) = \langle \nabla \mathcal{L}(\theta(t)), \dot{\theta}(t) \rangle \quad (\text{chain rule}) \quad (2.9)$$

$$= \langle \nabla \mathcal{L}(\theta(t)), -\nabla \mathcal{L}(\theta(t)) \rangle \quad (\text{GF: } \dot{\theta} = -\nabla \mathcal{L}) \quad (2.10)$$

$$= -\|\nabla \mathcal{L}(\theta(t))\|^2 \quad (2.11)$$

$$\leq 0. \quad (2.12)$$

즉

$$\boxed{\frac{d}{dt}\mathcal{L}(\theta(t)) = -\|\nabla \mathcal{L}(\theta(t))\|^2} \quad (2.13)$$

이다.

$t \in [0, T]$ 에 대해 적분하면

$$\mathcal{L}(\theta(T)) - \mathcal{L}(\theta(0)) = -\int_0^T \|\nabla \mathcal{L}(\theta(t))\|^2 dt, \quad (2.14)$$

$$\mathcal{L}(\theta(0)) - \mathcal{L}(\theta(T)) = \int_0^T \|\nabla \mathcal{L}(\theta(t))\|^2 dt. \quad (2.15)$$

따라서 GF에서 loss가 증가하는 구간은 없다.

핵심 EoS에서 loss가 step마다 위아래로 움직이는 현상은 **gradient flow**에서는 발생할 수 없다. 따라서 EoS를 이해하려면 “작은 learning rate의 연속시간 근사”만 봐서는 부족하다.

2.4 PL 조건 아래에서의 지수 수렴

최적값을 $\mathcal{L}_\star$ 라 하자. Polyak–Łojasiewicz(PL) 조건을

$$\frac{1}{2} \|\nabla \mathcal{L}(\theta)\|^2 \geq \mu(\mathcal{L}(\theta) - \mathcal{L}_\star) \quad (2.16)$$

라고 하자. 그러면 (2.12)에서

$$\frac{d}{dt}(\mathcal{L}(\theta(t)) - \mathcal{L}_\star) = -\|\nabla \mathcal{L}(\theta(t))\|^2 \quad (2.17)$$

$$\leq -2\mu(\mathcal{L}(\theta(t)) - \mathcal{L}_\star). \quad (2.18)$$

$g(t) = \mathcal{L}(\theta(t)) - \mathcal{L}_\star$ 라 두자. $g(t) > 0$ 인 동안에는 $g(t)$ 로 나눌 수 있으므로

$$\dot{g}(t) \leq -2\mu g(t), \quad (2.19)$$

$$\frac{\dot{g}(t)}{g(t)} \leq -2\mu, \quad (2.20)$$

$$\int_0^t \frac{\dot{g}(s)}{g(s)} ds \leq -2\mu t, \quad (2.21)$$

$$\log g(t) - \log g(0) \leq -2\mu t, \quad (2.22)$$

$$g(t) \leq g(0)e^{-2\mu t}. \quad (2.23)$$

어떤 시점에 $g(t) = 0$ 이 되면 이미 최적값에 도달한 것이므로 이후 결론은 자명하다. 따라서 전체적으로

$$\boxed{\mathcal{L}(\theta(t)) - \mathcal{L}_\star \leq e^{-2\mu t}(\mathcal{L}(\theta(0)) - \mathcal{L}_\star).} \quad (2.24)$$

보충 유도 — 논문 밖의 독자용 전개— **PL**과 **strong convexity**는 같은가? Strong convexity는 PL을 함의하지만 PL은 convexity를 요구하지 않는다. 따라서 과매개변수화된 비볼록 문제에서도 국소적으로 PL-type inequality가 성립하는 분석이 가능하다. Arora et al.의 부록에서도 최소점 manifold 근방에서 이런 형태의 제어를 사용한다.

2.5 Quadratic에서 GF를 정확히 풀기

가장 중요한 모델은

$$\mathcal{L}(x) = \frac{1}{2}x^\top Ax, \quad A = A^\top \succeq 0. \quad (2.25)$$

이다. 그러면

$$\nabla \mathcal{L}(x) = Ax, \quad (2.26)$$

$$\dot{x}(t) = -Ax(t). \quad (2.27)$$

해는 matrix exponential로

$$x(t) = e^{-At}x(0). \quad (2.28)$$

$A = Q\Lambda Q^\top$ 로 eigendecomposition 하고 $z = Q^\top x$ 를 두면

$$\dot{z}(t) = Q^\top \dot{x}(t) \quad (2.29)$$

$$= -Q^\top Ax(t) \quad (2.30)$$

$$= -Q^\top Q\Lambda Q^\top x(t) \quad (2.31)$$

$$= -\Lambda z(t). \quad (2.32)$$

따라서 각 eigenmode i 는 독립적으로

$$\dot{z}_i(t) = -\lambda_i z_i(t), \quad (2.33)$$

$$z_i(t) = e^{-\lambda_i t} z_i(0). \quad (2.34)$$

$\lambda_i > 0$ 이면 어떤 크기의 곡률이라도 연속시간 GF는 안정적으로 감쇠한다.

보충 유도 — 논문 밖의 독자용 전개— **steepest descent**라는 기하적 해석 현재 위치 θ 에서 순간 속도 v 를 고른다고 하자. 1차 loss 변화와 속도 비용의 합

$$\langle \nabla \mathcal{L}(\theta), v \rangle + \frac{1}{2} \|v\|^2$$

를 최소화하면

$$0 = \nabla_v \left(\langle \nabla \mathcal{L}, v \rangle + \frac{1}{2} \|v\|^2 \right) \quad (2.35)$$

$$= \nabla \mathcal{L} + v, \quad (2.36)$$

$$v^* = -\nabla \mathcal{L}. \quad (2.37)$$

즉 Euclidean metric에서 GF는 매 순간 가장 가파르게 내려가는 속도를 선택한다.

발표에서 이렇게 말하기 “GD update를 η 로 나누면 바로 difference quotient가 보입니다. 그래서 $t = k\eta$ 로 놓고 $\eta \rightarrow 0$ 을 취하면 $\dot{\theta} = -\nabla L$ 이 됩니다. 중요한 점은 이 연속시간 시스템에서는 $\dot{L} = -\|\nabla L\|^2$ 라서 loss가 절대로 올라가지 않는다는 것입니다. 이후 EoS에서 loss가 진동한다는 사실은 바로 이 GF 근사가 깨졌다는 신호입니다.”

3

유한 step size와 $2/\eta$ 안정성 경계

3.1 1차원 quadratic: 모든 것이 여기서 시작한다

$$f(x) = \frac{1}{2}ax^2 + bx + c, \quad a > 0 \quad (3.1)$$

를 생각하자. 최적점은

$$x_\star = -\frac{b}{a}. \quad (3.2)$$

GD는

$$x_{k+1} = x_k - \eta(ax_k + b). \quad (3.3)$$

오차 $e_k = x_k - x_\star$ 를 쓰면

$$e_{k+1} = x_{k+1} - x_\star \quad (3.4)$$

$$= x_k - x_\star - \eta(ax_k + b) \quad (3.5)$$

$$= e_k - \eta a(x_k - x_\star) \quad (ax_\star + b = 0) \quad (3.6)$$

$$= (1 - \eta a)e_k. \quad (3.7)$$

반복하면

$$\boxed{e_k = (1 - \eta a)^k e_0.} \quad (3.8)$$

수렴 조건은

$$|1 - \eta a| < 1 \quad (3.9)$$

$$-1 < 1 - \eta a < 1 \quad (3.10)$$

$$-2 < -\eta a < 0 \quad (3.11)$$

$$0 < \eta a < 2. \quad (3.12)$$

따라서

$$\boxed{a < \frac{2}{\eta}} \quad (3.13)$$

가 stability threshold다.

세 regime를 구분하자

조건	multiplier $1 - \eta a$	동역학
$0 < \eta a < 1$	$(0, 1)$	부호 변화 없이 감소
$1 < \eta a < 2$	$(-1, 0)$	좌우로 진동하며 감소
$\eta a = 2$	-1	크기 일정, period-2 진동
$\eta a > 2$	< -1	진동 크기가 커지며 발산

핵심 “oscillation” 자체와 “instability”는 구분해야 한다. $1 < \eta a < 2$ 에서도 부호는 매번 바뀌지만 크기는 감소한다. 진짜 quadratic stability boundary는 $\eta a = 2$ 다.

3.2 d 차원 quadratic: sharpness가 등장한다

$$f(x) = \frac{1}{2}x^\top Ax + b^\top x + c, \quad A = A^\top \succ 0. \quad (3.14)$$

최적점 $x_\star$ 에 대해 $e_k = x_k - x_\star$ 라 두면

$$e_{k+1} = (I - \eta A)e_k. \quad (3.15)$$

$A = Q\Lambda Q^\top$ 이고 $z_k = Q^\top e_k$ 이면

$$z_{k+1} = Q^\top e_{k+1} \quad (3.16)$$

$$= Q^\top (I - \eta A)e_k \quad (3.17)$$

$$= (I - \eta \Lambda)Q^\top e_k \quad (3.18)$$

$$= (I - \eta \Lambda)z_k. \quad (3.19)$$

따라서 각 성분은

$$z_{i,k+1} = (1 - \eta \lambda_i)z_{i,k}. \quad (3.20)$$

모든 방향이 안정하려면

$$|1 - \eta \lambda_i| < 1 \quad \forall i, \quad (3.21)$$

$$\eta \lambda_i < 2 \quad \forall i, \quad (3.22)$$

$$\eta \lambda_{\max}(A) < 2. \quad (3.23)$$

즉

$$\boxed{\lambda_{\max}(A) < \frac{2}{\eta}} \quad (3.24)$$

Cohen et al.은 neural-network training loss의 Hessian 최대 고유값을

$$\text{sharpness}(x) := \lambda_{\max}(\nabla^2 f(x)) \quad (3.25)$$

라고 정의한다.

3.3 GF와 GD가 curvature를 처리하는 방식의 차이

quadratic의 eigenmode 하나만 보면,

$$\text{GF:} \quad z_i(t + \eta) = e^{-\eta \lambda_i} z_i(t), \quad (3.26)$$

$$\text{GD:} \quad z_{i,k+1} = (1 - \eta \lambda_i)z_{i,k}. \quad (3.27)$$

Taylor expansion으로

$$e^{-\eta \lambda_i} = 1 - \eta \lambda_i + \frac{1}{2}(\eta \lambda_i)^2 - \frac{1}{6}(\eta \lambda_i)^3 + \dots. \quad (3.28)$$

즉 $\eta \lambda_i \ll 1$ 일 때만

$$1 - \eta \lambda_i \approx e^{-\eta \lambda_i} \quad (3.29)$$

이다. curvature가 learning-rate scale에 비해 커지면 둘은 질적으로 달라진다.

보충 유도 — 논문 밖의 독자용 전개 — 왜 GF에는 $2/\eta$ 가 없는가 GF multiplier $e^{-\eta\lambda}$ 는 $\lambda > 0$ 이면 항상 $(0, 1)$ 이다. 반면 GD multiplier $1 - \eta\lambda$ 는 유한한 Euler step 때문에 -1 아래로 내려갈 수 있다. 따라서 $2/\eta$ 는 원래 loss landscape의 고유한 상수가 아니라 **landscape curvature**와 **discretization step**의 상호작용으로 생기는 경계다.

3.4 Descent lemma에서 나타나는 $2/\beta$ 충분조건

$\mathcal{L}$ 가 β -smooth하다고 하자:

$$\|\nabla\mathcal{L}(x) - \nabla\mathcal{L}(y)\| \leq \beta \|x - y\|. \quad (3.30)$$

표준 descent lemma는

$$\mathcal{L}(y) \leq \mathcal{L}(x) + \langle \nabla\mathcal{L}(x), y - x \rangle + \frac{\beta}{2} \|y - x\|^2. \quad (3.31)$$

여기서 GD step $y = x - \eta\nabla\mathcal{L}(x)$ 를 대입한다.

$$\mathcal{L}(x - \eta\nabla\mathcal{L}(x)) \leq \mathcal{L}(x) + \langle \nabla\mathcal{L}(x), -\eta\nabla\mathcal{L}(x) \rangle + \frac{\beta}{2} \|\eta\nabla\mathcal{L}(x)\|^2 \quad (3.32)$$

$$= \mathcal{L}(x) - \eta \|\nabla\mathcal{L}(x)\|^2 + \frac{\beta\eta^2}{2} \|\nabla\mathcal{L}(x)\|^2 \quad (3.33)$$

$$= \mathcal{L}(x) - \eta \left(1 - \frac{\beta\eta}{2}\right) \|\nabla\mathcal{L}(x)\|^2. \quad (3.34)$$

따라서

$$1 - \frac{\beta\eta}{2} > 0 \iff \eta < \frac{2}{\beta} \quad (3.35)$$

이때 매 step의 monotone descent가 **보장**된다. 일반적인 nonlinear loss에서 이것은 exact stability boundary가 아니라 β -smoothness로부터 얻는 **충분조건**이다.

주의 여기서 β 는 보통 관심 영역 전체를 지배하는 smoothness constant다. 실험에서 측정하는 현재점의 sharpness $\lambda_{\max}(\nabla^2\mathcal{L}(x))$ 와 완전히 같은 개념은 아니다. 고정 PSD quadratic에서는 Hessian이 상수이고 $\beta = \lambda_{\max}(A)$ 이므로, 앞에서 구한 exact stability threshold $\eta\lambda_{\max}(A) < 2$ 와 일치한다.

3.5 비볼록 neural loss에서는 왜 $2/\eta$ 를 넘자마자 영원히 발산하지 않는가?

현재점 x_k 에서 2차 Taylor approximation을 쓰면

$$\mathcal{L}(x_k + \delta) \approx \mathcal{L}(x_k) + g_k^\top \delta + \frac{1}{2} \delta^\top H_k \delta. \quad (3.36)$$

H_k 가 고정된 quadratic라면 $\lambda_1(H_k) > 2/\eta$ 는 top eigendirection에서 발산을 뜻한다. 하지만 실제 neural loss에서는

$$H_{k+1} \neq H_k, \quad (3.37)$$

즉 iterate가 움직이면서 local quadratic 자체가 바뀐다. 따라서 local instability가 “전체 trajectory의 무조건적 발산”을 뜻하지는 않는다. 바로 이 점이 EoS의 출발점이다.

발표에서 이렇게 말하기 “ $2/\eta$ 는 1차원 quadratic에서 바로 나옵니다. 오차가 매 step마다 $1 - \eta\lambda$ 만큼 곱해지므로 그 절댓값이 1보다 작아야 합니다. 다차원에서는 Hessian eigenbasis로 분해하면 똑같은 식이 방향별로 생기고, 가장 먼저 깨지는 방향이 top Hessian eigenvector입니다. 그래서 sharpness가 핵심 변수가 됩니다.”

4

Cohen et al. (2021): Edge of Stability라는 관측

4.1 논문이 발견한 두 단계

Cohen et al.은 full-batch GD로 여러 neural network를 학습하면서 Hessian의 최대 고유값을 추적했다. 핵심 관측은 다음과 같다.

원 논문 기준

1. **Progressive sharpening:** sharpness가 $2/\eta$ 보다 충분히 작을 때 학습 중 점차 증가하는 경우가 많다.
2. **Edge of Stability:** sharpness가 $2/\eta$ 에 도달한 뒤에는 그 근처 또는 조금 위에서 머문다.
3. 이때 train loss는 step-by-step으로는 비단조적으로 진동하지만, 긴 시간축에서는 계속 감소한다.

이를 개념적으로 쓰면

$$\lambda_1(k) \uparrow \implies \eta\lambda_1(k) \approx 2 \implies \text{oscillatory but long-term decreasing loss.} \quad (4.1)$$

4.2 gradient flow trajectory와의 관계

논문을 여러 네트워크에서 GD가 처음에는 GF trajectory를 가까이 따라가다가, 그 trajectory 상에서 sharpness가 $2/\eta$ 에 도달하는 시점 부근에서 이탈하는 것을 관측한다. 시간축을 맞추려면 GD iteration k 를 GF time

$$t = k\eta \quad (4.2)$$

로 바꾼다.

GF trajectory의 초기 sharpness를 λ_0 , 그 trajectory에서 도달하는 최대 sharpness를 $\lambda_{\max}^{\text{GF}}$ 라고 쓰면, 논문의 경험적 그림은 다음처럼 이해할 수 있다.

- $\eta < 2/\lambda_{\max}^{\text{GF}}$ 라면 GF 경로를 따라가는 동안 threshold를 만나지 않는다.
- $2/\lambda_{\max}^{\text{GF}} \leq \eta \leq 2/\lambda_0$ 라면 처음에는 GF를 추적하지만, GF 경로의 sharpness가 $2/\eta$ 에 도달하는 부근에서 finite-step instability가 나타난다.

주의— 이것을 보편 정리처럼 말하면 안 된다. Cohen et al.의 핵심은 광범위한 **empirical observation**이다. 모든 architecture에서 GD가 GF를 정밀하게 추적한다는 정리가 아니다. 논문 부록의 WikiText-2 Transformer 실험에서는 EoS 형태의 sharpness 현상은 관찰하지만, 초기 GD trajectory가 GF trajectory를 가깝게 따라간다는 패턴은 관찰되지 않았다고 명시한다.

4.3 “progressive sharpening”이 왜 EoS를 피하기 어렵게 만드는가

고정 learning rate η 를 쓴다고 하자. 초기에는

$$\lambda_1(0) < \frac{2}{\eta} \quad (4.3)$$

여도, 학습 중

$$\lambda_1(k) \uparrow \quad (4.4)$$

하면 결국

$$\lambda_1(k) \approx \frac{2}{\eta} \quad (4.5)$$

에 도달할 수 있다. 즉 “초기 Hessian 만 보고 안정한 learning rate를 정한다”는 논리가 깨진다.

4.4 learning-rate drop 실험의 의미

EoS에서

$$\lambda_1 \approx \frac{2}{\eta_{\text{old}}} \quad (4.6)$$

라고 하자. learning rate를 줄여

$$\eta_{\text{new}} < \eta_{\text{old}} \quad (4.7)$$

로 만들면 새로운 stability threshold는

$$\frac{2}{\eta_{\text{new}}} > \frac{2}{\eta_{\text{old}}} \quad (4.8)$$

$$\approx \lambda_1. \quad (4.9)$$

즉 현재점이 다시 threshold 아래로 들어간다. Cohen et al.에서는 이 뒤 sharpness가 다시 상승하고, 새로운 $2/\eta_{\text{new}}$ 부근에서 멈추는 현상을 관찰한다.

핵심 이 실험은 “sharpness가 우연히 plateau한다”보다 강한 힌트를 준다. plateau 위치가 learning rate에 따라 이동하기 때문이다. 즉 training dynamics가 $\eta\lambda_1 \approx 2$ 라는 discretization scale과 결합되어 있다.

4.5 EoS는 classical quadratic stability와 모순인가?

아니다. 정확히는 다음 둘을 구분해야 한다.

1. **고정 quadratic:** H 가 변하지 않는다. $\eta\lambda_1 > 2$ 면 top mode가 기하급수적으로 발산한다.
2. **neural loss:** iterate가 움직일 때 gradient, Hessian, eigenvector가 모두 변한다. local quadratic의 unstable direction으로 overshoot해도 다음 step의 landscape는 달라진다.

따라서 EoS는 quadratic 분석이 “틀렸다”는 뜻이 아니라, quadratic의 local instability가 실제 비선형 landscape에서 어떤 장기 동역학으로 조직되는지가 새로운 문제라는 뜻이다.

4.6 LLM/Transformer 발표에서의 안전한 해석

주의 Cohen et al.의 대표 결과는 **full-batch deterministic GD**에 관한 것이다. 실제 대규모 LLM은 minibatch SGD 계열, Adam/AdamW, warmup, decay, normalization 등을 사용한다. 따라서 “LLM도 항상 sharpness = $2/\eta$ 에서 학습한다”고 일반화하면 안 된다. 세미나에서는 EoS를 **finite-step optimization dynamics**를 이해하기 위한 **canonical phenomenon**으로 소개하는 것이 정확하다.

4.7 논문에서 하지 않은 주장

Cohen et al.은 이 논문에서 sharpness를

$$\lambda_{\max}(\nabla^2 \mathcal{L}) \quad (4.10)$$

로 엄격히 정의하며, 이 양과 generalization 사이의 직접적 관계를 주장하지 않는다. 따라서 발표에서도 “EoS가 flatter minima를 찾아서 generalization이 좋아진다”를 Cohen et al.의 결론처럼 말하면 안 된다.

발표에서 이렇게 말하기 “Cohen et al.의 놀라운 관측은, sharpness가 $2/\eta$ 를 넘으면 quadratic 모델상 불안정해야 하는데 실제 neural loss에서는 학습이 완전히 발산하지 않는다는 것입니다. 대신 sharpness는 그 경계 근처에 고정되고 loss는 짧게는 진동하지만 길게는 감소합니다. 그리고 learning rate를 낮추면 경계 $2/\eta$ 가 위로 이동하고 sharpness가 다시 올라갑니다. 즉 plateau 위치가 learning rate와 직접 결합되어 있습니다.”

5

Arora–Li–Panigrahi (2022): EoS를 수학적으로 모델링하기

5.1 왜 현재점의 sharpness만으로는 부족한가?

Arora et al.은 한 GD step이 실제로 지나가는 선분 위의 curvature를 반영하기 위해 다음 **stablness**를 정의한다.

정의 5.1 (Stablness). Loss L , 점 x , learning rate $\eta > 0$ 에 대해

$$S_L(x, \eta) := \eta \sup_{0 \leq s \leq \eta} \lambda_1(\nabla^2 L(x - s \nabla L(x))). \quad (5.1)$$

$S_L(x, \eta) \leq 2$ 이면 stable, 그렇지 않으면 unstable이라 부른다.

현재점 하나에서의 $\eta \lambda_1(\nabla^2 L(x))$ 가 아니라, 한 step segment

$$\{x - s \nabla L(x) : 0 \leq s \leq \eta\} \quad (5.2)$$

전체를 본다는 점이 중요하다.

보충 유도 — 논문 밖의 독자용 전개 — 왜 이 정의에서 정확히 2가 나오는가 $g = \nabla L(x)$ 라 두고 $\psi(s) = L(x - sg)$ 를 정의한다. 그러면

$$\psi'(s) = -g^\top \nabla L(x - sg), \quad (5.3)$$

$$\psi''(s) = g^\top \nabla^2 L(x - sg)g. \quad (5.4)$$

Taylor의 적분형 나머지를 쓰면

$$L(x - \eta g) = L(x) + \eta \psi'(0) + \int_0^\eta (\eta - s) \psi''(s) ds \quad (5.5)$$

$$= L(x) - \eta \|g\|^2 + \int_0^\eta (\eta - s) g^\top \nabla^2 L(x - sg)g ds. \quad (5.6)$$

최대 고유값으로 상계하면

$$L(x - \eta g) \leq L(x) - \eta \|g\|^2 + \sup_{0 \leq s \leq \eta} \lambda_1(\nabla^2 L(x - sg)) \|g\|^2 \int_0^\eta (\eta - s) ds \quad (5.7)$$

$$= L(x) - \eta \|g\|^2 + \frac{\eta^2}{2} \sup_{0 \leq s \leq \eta} \lambda_1(\nabla^2 L(x - sg)) \|g\|^2 \quad (5.8)$$

$$= L(x) - \eta \left(1 - \frac{S_L(x, \eta)}{2}\right) \|g\|^2. \quad (5.9)$$

따라서 $S_L(x, \eta) < 2$ 면 그 step의 loss decrease가 보장된다. 이 계산은 논문의 Definition 1.1 뒤에 있는 local descent-lemma 직관을 풀어 쓴 것이다.

5.2 EoS를 만드는 두 메커니즘

논문은 적어도 두 설정에서 EoS를 엄밀히 분석한다.

메커니즘 A: Normalized GD의 effective learning rate 폭증

Normalized GD는

$$x_{k+1} = x_k - \eta \frac{\nabla L(x_k)}{\|\nabla L(x_k)\|}. \quad (5.10)$$

이를 일반 GD처럼 다시 쓰면

$$x_{k+1} = x_k - \eta_k^{\text{eff}} \nabla L(x_k), \quad (5.11)$$

$$\eta_k^{\text{eff}} := \frac{\eta}{\|\nabla L(x_k)\|}. \quad (5.12)$$

최소점에 접근하여

$$\|\nabla L(x_k)\| \rightarrow 0 \quad (5.13)$$

이면

$$\boxed{\eta_k^{\text{eff}} \rightarrow \infty.} \quad (5.14)$$

즉 L 자체가 smooth해도 알고리즘이 자동으로 effective step size를 키워 안정성 경계에 부딪힐 수 있다.

메커니즘 B: $\sqrt{L}$ 가 최소점 근처에서 non-smooth해짐

$L \geq 0$ 이고 최소값이 0이라 하자. 새로운 목적함수

$$\tilde{L}(x) = \sqrt{L(x)} \quad (5.15)$$

를 생각한다. $L(x) > 0$ 인 곳에서

$$\nabla \tilde{L}(x) = \nabla \left(L(x)^{1/2} \right) \quad (5.16)$$

$$= \frac{1}{2\sqrt{L(x)}} \nabla L(x). \quad (5.17)$$

한 번 더 미분하면

$$\nabla^2 \tilde{L}(x) = \frac{1}{2\sqrt{L}} \nabla^2 L + \nabla \left(\frac{1}{2\sqrt{L}} \right) (\nabla L)^\top \quad (5.18)$$

$$= \frac{1}{2\sqrt{L}} \nabla^2 L - \frac{1}{4L^{3/2}} \nabla L \nabla L^\top \quad (5.19)$$

$$= \boxed{\frac{2L \nabla^2 L - \nabla L \nabla L^\top}{4L^{3/2}}}. \quad (5.20)$$

$L \rightarrow 0$ 이면 denominator가 $L^{3/2}$ 로 사라지므로 curvature가 커질 수 있다. 논문은 적절한 rank 조건 아래 최소점에 접근할 때 이 Hessian의 발산을 이용한다.

핵심 두 메커니즘은 겉보기에는 다르지만 공통 구조가 있다. minimum 근처에서는 “step size $\times$ curvature”가 더 이상 작은 무차원량으로 유지되지 않는다. Normalized GD에서는 effective step이 커지고, $\sqrt{L}$ 에서는 effective curvature가 커진다.

5.3 최소점 하나가 아니라 manifold를 본다

과매개변수화 문제에서는 최소점이 고립된 점 하나가 아니라 manifold를 이룰 수 있다. 논문은

$$\Gamma = \{x : L(x) = 0\} \quad (5.21)$$

를 $(D - M)$ 차원 local-minimizer manifold로 가정하고, $x \in \Gamma$ 에서

$$\text{rank}(\nabla^2 L(x)) = M \quad (5.22)$$

을 가정한다. 즉 Hessian의 M 개 normal direction에는 curvature가 있고, manifold를 따라가는 tangent direction에는 zero modes가 존재하는 그림이다.

GF limiting map Φ

GF를

$$\phi(x, \tau) = x - \int_0^\tau \nabla L(\phi(x, s)) ds \quad (5.23)$$

라고 하고, GF가 Γ 로 수렴하는 neighborhood U 에서

$$\boxed{\Phi(x) := \lim_{\tau \rightarrow \infty} \phi(x, \tau) \in \Gamma} \quad (5.24)$$

를 정의한다. 즉 $\Phi(x)$ 는 “현재 점 x 에서 infinitesimal-step GF만 계속 돌렸을 때 도착하는 최소점”이다.

원 논문 기준— **projection notation** Arora et al.은 $P_{x,\Gamma}$ 를 **normal space**로의 projection, $P_{x,\Gamma}^\perp = I - P_{x,\Gamma}$ 를 **tangent space**로의 projection으로 쓴다. 일반적인 직관과 기호가 헷갈릴 수 있으므로 발표에서는

$$P_\Gamma(x) := P_{x,\Gamma}^\perp$$

라고 다시 이름 붙여 설명하는 것이 안전하다.

5.4 두 시간축: Phase I과 Phase II

Arora et al.의 핵심 구조는 두 개의 서로 다른 time scale이다.

Phase I: GF를 따라 minimum manifold로 접근

작은 η 에서 대략

$$k = \Theta(\eta^{-1}) \quad (5.25)$$

개의 step 동안 움직인다. Normalized GD의 연속시간 변수는

$$\tau = k\eta = \Theta(1) \quad (5.26)$$

로 잡는 것이 정확하다. 이 극한은

$$\frac{dx}{d\tau} = -\frac{\nabla L(x)}{\|\nabla L(x)\|} \quad (5.27)$$

인 **normalized gradient flow**이다. 이 flow는 표준 GF $\dot{x} = -\nabla L(x)$ 와 같은 궤적을 지나지만 속도, 즉 time parametrization은 다르다. 따라서 이 구간에서 iterate는 GF 경로를 따라 Γ 의 $O(\eta)$ 근방까지 접근한다고 이해하면 된다.

Phase II: 빠른 진동 + 느린 tangent drift

Γ 근방에 도달하면 normal direction, 특히 top-curvature direction으로 overshoot가 반복된다. 한편 $\Phi(x_k)$ 의 tangent movement는 한 step에 $O(\eta^2)$ 규모이므로, $O(1)$ 크기의 tangent 이동을 보기 위해서는

$$k = \Theta(\eta^{-2}) \quad (5.28)$$

step이 필요하다. 따라서 slow time을

$$\tau = k\eta^2 \quad (5.29)$$

로 잡는다.

핵심

$$\text{Phase I: } k \sim \eta^{-1}$$

$$\text{Phase II: } k \sim \eta^{-2}$$

Phase II에서는 매 step의 큰 oscillation과, 여러 step을 평균냈을 때 보이는 작은 drift를 분리해서 봐야 한다.

5.5 limiting flow: EoS가 sharpness를 낮추는 방향으로 움직인다

Top Hessian eigenvalue를

$$\lambda_1(x) := \lambda_1(\nabla^2 L(x)), \quad x \in \Gamma \quad (5.30)$$

라고 하자. top eigenvalue가 simple하다는 등의 regularity 조건 아래, 논문의 Phase-II limiting flow는 다음 형태다.

Normalized GD

$$\frac{dX}{d\tau} = -\frac{1}{4} P_{\Gamma}(X) \nabla \log \lambda_1(X) \quad (5.31)$$

즉 manifold 위에서 $\log \lambda_1$ 의 Riemannian gradient flow다. 논문식 적분형은

$$X(\tau) = \Phi(x_{\text{init}}) - \frac{1}{4} \int_0^\tau P_{X(s), \Gamma}^\perp \nabla \log \lambda_1(X(s)) ds. \quad (5.32)$$

GD on $\sqrt{L}$

$$\frac{dX}{d\tau} = -\frac{1}{8} P_{\Gamma}(X) \nabla \lambda_1(X) \quad (5.33)$$

즉 manifold 위에서 sharpness λ_1 자체를 줄이는 gradient flow다.

보충 유도 — 논문 밖의 독자용 전개— limiting flow가 정말 sharpness를 감소시키는지 한 줄씩 확인 Normalized GD의 경우 $q(X) = \log \lambda_1(X)$ 라 두면

$$\frac{d}{d\tau} q(X(\tau)) = \langle \nabla q(X), \dot{X} \rangle \quad (5.34)$$

$$= \langle \nabla q(X), -\frac{1}{4} P_{\Gamma}(X) \nabla q(X) \rangle \quad (5.35)$$

$$= -\frac{1}{4} \langle \nabla q, P_{\Gamma} \nabla q \rangle \quad (5.36)$$

$$= -\frac{1}{4} \|P_{\Gamma} \nabla q\|^2 \quad (5.37)$$

$$\leq 0. \quad (5.38)$$

마지막 줄은 P_{Γ} 가 orthogonal projection이기 때문이다.

GD on $\sqrt{L}$ 에서는 같은 계산으로

$$\frac{d}{d\tau} \lambda_1(X(\tau)) = \langle \nabla \lambda_1, -\frac{1}{8} P_{\Gamma} \nabla \lambda_1 \rangle \quad (5.39)$$

$$= -\frac{1}{8} \|P_{\Gamma} \nabla \lambda_1\|^2 \quad (5.40)$$

$$\leq 0. \quad (5.41)$$

따라서 “EoS의 느린 평균 동역학이 flatter part of the minimum manifold로 이동한다”는 말을 정확히 수식으로 표현할 수 있다.

5.6 논문의 toy loss로 직접 확인하기

논문 Figure 1의 예시는

$$L(x, y) = (1 + x^2)y^2 \quad (5.42)$$

이다. zero-loss manifold는

$$\Gamma = \{(x, 0) : x \in \mathbb{R}\}. \quad (5.43)$$

보충 유도 — 논문 밖의 독자용 전개 — **Figure 1 toy example의 Hessian 계산** 먼저 gradient는

$$\frac{\partial L}{\partial x} = 2xy^2, \quad (5.44)$$

$$\frac{\partial L}{\partial y} = 2(1 + x^2)y. \quad (5.45)$$

따라서 Hessian은

$$\nabla^2 L(x, y) = \begin{pmatrix} 2y^2 & 4xy \\ 4xy & 2(1 + x^2) \end{pmatrix}. \quad (5.46)$$

Γ 위, 즉 $y = 0$ 에서는

$$\nabla^2 L(x, 0) = \begin{pmatrix} 0 & 0 \\ 0 & 2(1 + x^2) \end{pmatrix}. \quad (5.47)$$

따라서

$$\lambda_1(x, 0) = 2(1 + x^2). \quad (5.48)$$

이는 $x = 0$ 에서 최소다. 즉 EoS의 slow tangent drift가 $|x|$ 를 줄이는 방향이라는 논문의 그림과 정확히 맞는다.

예를 들어 GD on $\sqrt{L}$ 의 limiting flow를 대입하면

$$\frac{dx}{d\tau} = -\frac{1}{8} \frac{d}{dx} [2(1 + x^2)] \quad (5.49)$$

$$= -\frac{1}{8} (4x) \quad (5.50)$$

$$= -\frac{1}{2} x, \quad (5.51)$$

따라서

$$x(\tau) = x(0)e^{-\tau/2} \rightarrow 0. \quad (5.52)$$

이 마지막 ODE 해는 설명을 위한 보충 계산이다.

5.7 “implicit regularization”이라는 말의 정확한 의미

여기서 explicit objective는 여전히 L 또는 $\sqrt{L}$ 이다. 하지만 finite-step GD가 EoS에 들어가면, 빠른 oscillation을 평균낸 느린 dynamics는 minimum manifold 위에서 별도의 양

$$\lambda_1(\nabla^2 L) \quad \text{또는} \quad \log \lambda_1(\nabla^2 L) \quad (5.53)$$

을 낮추는 흐름으로 나타난다. 즉 loss가 이미 최소인 점들 사이에서도 알고리즘 자체가 특정 해를 선호한다. 이것이 이 문맥의 implicit regularization이다.

주의— 이론의 적용 범위 Arora et al.의 정리는 일반적인 모든 deep net + 일반 GD에 대한 완전한 EoS 이론이 아니다. 핵심 rigorous setting은 (i) Normalized GD on smooth L , (ii) constant-step GD on $\sqrt{L - L_{\min}}$ 이고, minimum manifold의 smoothness, Hessian rank, top-eigenvalue gap 등 regularity assumption을 둔다. Phase-II 증명에는 기술적으로 매우 작은 perturbation도 도입한다. 논문은 실제 실험에서는 deterministic GD에서도 예측이 맞는다고 보고한다.

발표에서 이렇게 말하기 “Arora et al.의 핵심은 EoS 진동 자체보다 그 진동의 평균 효과입니다. 먼저 $O(1/\eta)$ step 동안 GF처럼 minimum manifold에 접근합니다. 그 다음에는 top-curvature normal direction으로 빠르게 왕복하지만, 매 step $O(\eta^2)$ 만큼 manifold의 tangent direction으로 drift합니다. 그래서 $O(1/\eta^2)$ step의 느린 시간축에서 보면 이 drift가 sharpness를 줄이는 gradient flow로 수렴합니다.”

6

Gradient Flow와 EoS를 하나의 그림으로 연결하기

6.1 세 가지 dynamics를 분리해서 보자

Regime	지배 방정식	핵심 안정성	관찰되는 현상
Gradient Flow	$\dot{x} = -\nabla L(x)$	finite-step threshold 없음	L 이 연속적으로 감소
Stable plain GD	$x_{k+1} = x_k - \eta \nabla L(x_k)$	local quadratic에서 $\eta \lambda_1 < 2$	GF를 근사할 수 있음
Cohen의 EoS	fixed-step plain GD, $\eta \lambda_1 \approx 2$	local quadratic marginal/unstable	빠른 oscillation + 느린 장기 progress

6.2 왜 “GF가 GD의 근사”라는 말이 EoS에서는 실패하는가

정확한 GF 해를 한 step 길이 η 만큼 Taylor-expand해 보자. $g = \nabla L(x(t))$, $H = \nabla^2 L(x(t))$ 라 쓰면

$$\dot{x}(t) = -g, \quad (6.1)$$

$$\ddot{x}(t) = -H\dot{x}(t) = Hg, \quad (6.2)$$

이므로, 충분한 매끄러움 아래

$$x(t + \eta) = x(t) - \eta g + \frac{\eta^2}{2} Hg + O(\eta^3). \quad (6.3)$$

반면 한 번의 GD/Euler step은 $x(t) - \eta g$ 까지만 취한다. 따라서 leading correction과 Euler step의 크기 비는 대략

$$\frac{\left\| \frac{\eta^2}{2} Hg \right\|}{\|\eta g\|} \leq \frac{\eta}{2} \|H\|. \quad (6.4)$$

즉 η 자체보다 중요한 양은 curvature와 결합된 $\eta \|H\|$ 이다. 특히 top mode가 지배하면 이를 $\eta \lambda_1$ 로 읽을 수 있다. $\lambda_1 = O(1/\eta)$ 이면 이 보정항은 leading step과 같은 차수가 되어 GF 근사가 더 이상 uniform하게 작다고 볼 수 없다.

핵심 “small learning rate”는 절대적인 개념이 아니다. Plain GD의 local quadratic picture에서는

$$\eta \lambda_1 \ll 1$$

일 때 GF 근사가 가장 자연스럽다. Cohen et al.이 관찰한 fixed-step plain GD의 EoS는 이 값이 2 근처에 이르는 regime이다. Normalized GD나 GD on $\sqrt{L}$ 에서는 같은 내용을 단순히 현재점의 $\eta \lambda_1$ 하나로 표현하지 않고, effective step 또는 path-wise stableness를 사용해야 한다.

6.3 EoS의 period-2 구조를 local eigenmode로 읽기

Top Hessian eigenvector v_1 방향 좌표를 z_k 라고 하자. local quadratic approximation에서는

$$z_{k+1} \approx (1 - \eta\lambda_1)z_k. \quad (6.5)$$

EoS에서

$$\eta\lambda_1 \approx 2 \quad (6.6)$$

이므로

$$1 - \eta\lambda_1 \approx -1. \quad (6.7)$$

따라서

$$z_{k+1} \approx -z_k, \quad (6.8)$$

$$z_{k+2} \approx z_k. \quad (6.9)$$

이것이 2-step oscillation이 자연스럽게 등장하는 가장 간단한 이유다.

보충 유도 — 논문 밖의 독자용 전개 — 왜 2-step 평균을 자주 보는가 한 step에서는 $z_k \mapsto -z_k$ 라는 큰 변화가 있어도 두 step 뒤에는 normal coordinate가 거의 원상복구될 수 있다. 그러면 $x_{k+2} - x_k$ 에는 빠른 normal oscillation이 상쇄되고 $O(\eta^2)$ 의 작은 tangent drift가 남는다. Arora et al.의 Phase-II 분석에서 두 step 단위 평균과 η^{-2} time scale이 자연스러운 이유를 이 그림으로 기억하면 된다.

6.4 GF endpoint와 finite-step solution selection

GF만 보면 초기점 x 는

$$x \mapsto \Phi(x) \in \Gamma \quad (6.10)$$

로 간다. 그러나 finite-step EoS dynamics는 $\Phi(x)$ 에 도착한 뒤 멈추는 대신, Γ 근처에서 oscillation하며

$$\Phi(x_k) \quad (6.11)$$

자체를 천천히 움직일 수 있다.

따라서 conceptual decomposition은

$$\boxed{\text{fast attraction to } \Gamma \quad + \quad \text{fast normal oscillation} \quad + \quad \text{slow tangent drift}} \quad (6.12)$$

이다.

6.5 발표에서 자주 나올 질문

Q1. $\lambda_1 > 2/\eta$ 면 왜 발산하지 않나요?

고정 quadratic라면 발산한다. 실제 neural loss는 iterate와 함께 Hessian이 바뀌므로 local instability가 장기 발산을 강제하지 않는다. EoS는 바로 그 비선형 피드백이 만들어내는 동역학이다.

Q2. EoS와 chaos는 같은 말인가요?

아니다. Cohen et al.의 fixed-step plain GD에서는 $\eta\lambda_1 \approx 2$ 부근의 oscillatory finite-step regime이 대표적인 EoS 모습이다. Arora et al.의 특수 설정에서는 현재점의 $\eta\lambda_1$ 대신 알고리즘에 맞는 stableness를 보며, 빠른 oscillation을 평균하면 결정론적인 limiting flow가 나타난다.

Q3. sharpness가 작을수록 generalization이 좋은가요?

이 세미나 범위의 두 핵심 논문만으로 그렇게 결론내리면 안 된다. Cohen et al.은 자신들이 쓰는 sharpness와 generalization의 연결을 주장하지 않는다.

Q4. Adam에서도 $2/\eta$ 인가요?

그대로 아니다. $2/\eta$ 는 plain GD의 quadratic stability에서 나온다. preconditioning, momentum, adaptive step은 stability polynomial 자체를 바꾼다. Cohen et al.도 momentum의 maximum stable sharpness가 다른 식을 따른다고 분석한다.

Q5. 그럼 GF는 실전 학습을 설명하는 데 쓸모가 없나요?

아니다. Stable regime, 초기 dynamics, implicit bias 분석에서 여전히 핵심 baseline이다. 다만 EoS처럼 finite-step effect가 지배적인 구간에서는 GF만으로 설명할 수 없다는 것이 포인트다.

발표에서 이렇게 말하기 “정리하면 GF는 loss landscape의 연속시간 기하를 보여주고, EoS는 discretization이 그 기하와 강하게 상호작용할 때 생깁니다. 초기에는 GD가 GF를 따라갈 수 있지만 progressive sharpening 때문에 $\eta\lambda_1$ 이 2에 접근하면 top mode가 거의 부호 반전하는 period-2 mode가 됩니다. 그 빠른 진동을 평균하면 최소점 manifold를 따라 sharpness를 줄이는 느린 흐름이 나타날 수 있습니다.”

7

발표 준비용 압축 정리

7.1 칠판에 반드시 남길 8개 식

1. GD:

$$x_{k+1} = x_k - \eta \nabla L(x_k)$$

2. GF:

$$\dot{x} = -\nabla L(x)$$

3. GF energy identity:

$$\frac{d}{dt} L(x(t)) = -\|\nabla L(x(t))\|^2 \leq 0$$

4. 1D quadratic mode:

$$e_{k+1} = (1 - \eta\lambda)e_k$$

5. GD stability threshold:

$$\eta\lambda_{\max} < 2$$

6. Cohen et al.의 fixed-step plain GD에서의 EoS empirical condition:

$$\lambda_1(\nabla^2 L) \approx \frac{2}{\eta}$$

7. Arora et al. stableness:

$$S_L(x, \eta) = \eta \sup_{0 \leq s \leq \eta} \lambda_1(\nabla^2 L(x - s\nabla L(x)))$$

8. Phase-II limiting flows:

$$\dot{X} = -\frac{1}{4} P_{\top} \nabla \log \lambda_1 \quad \text{or} \quad \dot{X} = -\frac{1}{8} P_{\top} \nabla \lambda_1$$

7.2 발표 순서 추천

1. **1D quadratic**로 $2/\eta$ 를 먼저 유도한다.
2. 그 다음 GF를 보여주며 “continuous time에는 이 instability가 없다”고 대비한다.
3. Cohen et al.의 progressive sharpening $\rightarrow$ EoS 관측을 소개한다.
4. “왜 안 터지고 계속 학습되지?”를 질문으로 던진다.
5. Arora et al.의 manifold + two-time-scale 그림으로 답한다.
6. 마지막에 “finite step 자체가 implicit regularizer가 될 수 있다”로 마무리한다.

7.3 혼한 실수 체크리스트

- ☐ $2/\eta$ 를 GF stability threshold라고 말하지 않았는가?
- ☐ oscillation($\eta\lambda > 1$)과 divergence($\eta\lambda > 2$)를 구분했는가?
- ☐ current-point sharpness와 path-wise stableness를 구분했는가?
- ☐ Cohen et al.의 empirical observation과 Arora et al.의 rigorous special setting을 구분했는가?
- ☐ $P_{x,\Gamma}^\perp$ 가 Arora 표기에서는 tangent projection임을 확인했는가?
- ☐ Phase I의 η^{-1} scale과 Phase II의 η^{-2} scale을 구분했는가?
- ☐ EoS 결과를 Adam/SGD/실제 LLM에 무조건 일반화하지 않았는가?
- ☐ sharpness와 generalization의 직접 관계를 이 두 논문의 결론처럼 말하지 않았는가?

7.4 30초 결론

핵심 Gradient flow는 GD의 infinitesimal-step limit이며 loss를 항상 감소시킨다. 고정 quadratic, 또는 Hessian을 한 step 동안 고정한 local model에서는 각 eigenmode가 $1 - \eta\lambda_i$ 의 multiplier를 가지므로 $\eta\lambda_1 \approx 2$ 에서 period-2 경계가 나타난다. Cohen et al.의 fixed-step plain GD 실험에서는 progressive sharpening 때문에 neural network가 이 경계에 실제로 도달하고, 그 뒤에도 완전히 발산하지 않고 장기적으로 loss를 줄이는 EoS가 관측된다. 특정 이론적 설정에서는 이 빠른 oscillation의 평균 효과가 최소점 manifold를 따라 sharpness를 낮추는 느린 gradient flow로 수렴한다.

발표에서 이렇게 말하기 “Gradient flow는 learning rate를 0으로 보낸 이상적인 baseline이고, Edge of Stability는 finite step이 landscape의 curvature와 강하게 상호작용할 때 나타나는 현상입니다. Cohen et al.의 fixed-step plain GD에서는 핵심 무차원량 $\eta\lambda_1$ 이고, 이것이 2에 가까워지면 top-curvature 방향이 거의 period-2로 진동합니다. Arora et al.의 특수 설정에서는 그 빠른 진동을 평균한 느린 dynamics가 minimum manifold 위의 solution selection을 만들 수 있습니다.”

참고문헌 및 원문에서 확인할 위치

1. Jeremy M. Cohen, Simran Kaur, Yuanzhi Li, J. Zico Kolter, Ameet Talwalkar. “Gradient Descent on Neural Networks Typically Occurs at the Edge of Stability”. ICLR 2021.
<https://arxiv.org/abs/2103.00065>
특히 Section 2 (quadratic stability), Section 3 (progressive sharpening / EoS), Appendix J (Transformer on WikiText-2)을 확인할 것.
2. Sanjeev Arora, Zhiyuan Li, Abhishek Panigrahi. “Understanding Gradient Descent on the Edge of Stability in Deep Learning”. ICML 2022, PMLR 162.
<https://proceedings.mlr.press/v162/arora22a.html>
특히 Definition 1.1 (stability), Section 4.1–4.5 (GF map, manifold assumptions, Phase I/II, limiting flow, EoS theorem)을 확인할 것.

주의— 원문과 이 노트의 경계 “보충 유도” 박스의 계산은 발표 이해를 위해 원 논문의 정의와 결과에서 직접 전개한 설명이다. 정리의 모든 기술적 가정과 확률적 오차항을 재현한 완전한 proof note는 아니다. 발표에서 theorem statement를 엄밀히 인용해야 할 경우에는 위 원문의 해당 theorem을 그대로 확인할 것.