

Mean-Field Theory와 Infinite-Width Dynamics

particle dynamics에서 Wasserstein gradient flow까지

폭이 큰 two-layer network를 개별 뉴런의 고차원 최적화 문제로만 보지 않고, 뉴런 파라미터들의 **empirical distribution**이 시간에 따라 움직이는 입자계로 본다. finite-width particle system에서 measure-valued risk, continuity equation, Wasserstein gradient flow를 차례로 만들고, Mei-Montanari-Nguyen의 particle-to-PDE limit와 Chizat-Bach의 optimal-transport 관점을 연결한다. 마지막에는 “infinite width”가 곧 “NTK/lazy”를 뜻하지 않는 이유를 scaling 관점에서 분리한다.

Primary readings

Mei, Montanari, Nguyen, **A Mean Field View of the Landscape of Two-Layer Neural Networks**, PNAS 2018 / arXiv:1804.06561.

Chizat, Bach, **On the Global Convergence of Gradient Descent for Over-parameterized Models using Optimal Transport**, NeurIPS 2018.

Chizat, Oyallon, Bach, **On Lazy Training in Differentiable Programming**, NeurIPS 2019.

Contents

1	먼저 맞춰 둘 기호와 전체 그림	3
1.1	기호 대응표	3
1.2	이번 주차의 논리 사슬	3
2	Two-layer network를 particle system으로 보기	5
2.1	출발점: 뉴런의 평균으로 쓰인 network	5
2.2	square loss를 pairwise interaction energy로 전개	5
2.3	왜 이것이 “particle system”인가	6
2.4	finite-width gradient의 크기와 time scaling	6
3	Empirical measure와 infinite-width risk	7
3.1	순열 대칭을 없애는 empirical measure	7
3.2	finite risk가 measure functional로 정확히 다시 써진다	7
3.3	첫 번째 variation: measure 공간에서의 gradient 역할	7
3.4	measure에 대해 convex하다는 말	8
4	Continuity equation과 Wasserstein gradient flow	9
4.1	움직이는 particle은 어떤 PDE를 만드는가	9
4.2	mean-field velocity를 넣기	9
4.3	W_2 는 “분포를 옮기는 데 필요한 제곱거리”다	10
4.4	JKO step: Euclidean proximal step의 measure 버전	10
4.5	risk dissipation을 직접 계산	10
5	Mei–Montanari–Nguyen: particle에서 PDE로	12
5.1	SGD의 scaling	12
5.2	limit statement의 구조	12
5.3	propagation of chaos는 무엇을 뜻하는가	12
5.4	왜 PDE가 유용한가	13
6	Fixed point와 convexity: 왜 아직 문제가 남는가	14
6.1	risk가 감소한다고 global optimum에 가는 것은 아니다	14
6.2	global optimum의 조건은 더 강하다	14
6.3	“measure에 대해 convex”인데 왜 stationary trap이 가능한가	14
6.4	noisy SGD에서는 diffusion이 무엇을 바꾸는가	15
7	Chizat–Bach: optimal transport로 본 global convergence	16
7.1	조금 더 일반적인 measure optimization	16
7.2	particle gradient flow에서 Wasserstein flow로	16
7.3	Mei et al.과 무엇이 같은가	16
7.4	global convergence는 어떤 추가 구조를 쓰는가	17
7.5	ReLU에서 homogeneity가 왜 자연스러운가	17
8	Infinite width는 하나의 regime이 아니다	18
8.1	mean-field와 lazy training의 차이	18
8.2	lazy training은 정확히 무엇인가	18

8.3	표로 정리하는 두 regime	19
8.4	다음 주 NTK와의 연결	19
9	발표 준비용 압축 정리	20
9.1	칠판에 반드시 남길 여섯 식	20
9.2	발표 순서 추천	20
9.3	자주 나오는 질문	20
9.4	흔한 수학적 실수 체크리스트	21
9.5	30초 결론	21
	참고문헌 및 원문에서 확인할 위치	22

1

먼저 맞춰 둘 기호와 전체 그림

1.1 기호 대응표

세 논문은 거의 같은 구조를 서로 다른 언어로 쓴다. 이 노트에서는 measure를 주로 ρ , width를 N , neuron parameter를 θ 로 쓰고, 원문을 인용할 때만 각 논문의 표기를 병기한다.

개념	이 노트	Mei et al.	Chizat–Bach	Lazy paper
폭 / 입자 수	N	N	m	m
뉴런 파라미터	θ_i	θ_i	u_i 또는 (w_i, θ_i)	$w = (\theta_1, \dots, \theta_m)$
empirical measure	$\hat{\rho}_N$	$\hat{\rho}^{(N)}$	$\mu_{m,t}$	직접 중심 변수 아님
measure risk	$\mathcal{R}(\rho)$	$R(\rho)$	$F(\mu)$	$R(h(w))$
finite-width risk	$\mathcal{R}_N$	$R_N(\theta)$	$F_m(u)$	$F_\alpha(w)$
interaction potential	U	$U(\theta, \theta')$	일반 feature map Φ	—
1차 potential	Ψ	$\Psi(\theta; \rho)$	$F'(\mu)(u)$	—
연속시간	t	$t = k\varepsilon$	t	t
step-size scale	ε	$s_k = \varepsilon\xi(k\varepsilon)$	GF라 직접 없음	scale α
measure metric	W_2	W_2	W_2	Euclidean parameter space

주의— ρ 의 중복 사용 Chizat–Bach의 neural-network case에서는 데이터 분포에도 ρ 를 사용한다. 이 노트에서는 혼동을 피하기 위해 데이터 분포를 P 또는 P_{XY} 로 쓰고, 파라미터 분포를 ρ 또는 μ 로 쓴다.

1.2 이번 주치의 논리 사슬

1. two-layer network는

$$f_N(x) = \frac{1}{N} \sum_{i=1}^N \sigma_*(x; \theta_i)$$

처럼 동일한 형태의 뉴런을 평균낸 것이다.

2. 따라서 순서가 없는 집합 $\{\theta_i\}_{i=1}^N$ 대신

$$\hat{\rho}_N = \frac{1}{N} \sum_{i=1}^N \delta_{\theta_i}$$

를 상태 변수로 쓰는 것이 자연스럽다.

3. width $N \rightarrow \infty$ 에서 empirical measure가 매끄러운 분포 ρ_t 로 수렴하면, $N \times D$ 개의 ODE 대신 하나의 measure-valued PDE를 얻는다.

4. 그 PDE는 단순한 임의의 PDE가 아니라

$$\partial_t \rho_t = \nabla \cdot \left(\rho_t \nabla \frac{\delta \mathcal{R}}{\delta \rho}(\rho_t) \right)$$

꼴의 **Wasserstein gradient flow**다.

5. 중요한 점은 “width $\rightarrow \infty$ ”가 dynamics를 하나로 정하지 않는다는 것이다. $1/N$ scaling에서는 뉴런이 $O(1)$ 만큼 움직이는 mean-field dynamics가 남을 수 있고, 다른 scaling에서는 initialization 주변 선형화에 갇히는 lazy regime이 나타난다.

핵심 이번 주치의 핵심 질문은 “무한히 넓은 network의 함수가 무엇인가?”보다 “무한히 많은 뉴런의 학습 dynamics를 어떤 연속적인 객체로 기술할 수 있는가?”에 가깝다. 그 객체가 파라미터 분포 ρ_t 이고, 그 dynamics가 Wasserstein gradient flow다.

발표에서 이렇게 말하기 이번 주는 network width를 크게 했을 때 함수값의 분포만 보는 것이 아니라, 학습 중 뉴런들의 분포 자체가 어떻게 움직이는지를 본다. finite network의 뉴런을 particle로 보고 empirical measure를 만들면, infinite-width limit에서 particle ODE가 하나의 nonlinear PDE로 바뀐다.

2

Two-layer network를 particle system으로 보기

2.1 출발점: 뉴런의 평균으로 쓰인 network

Mei–Montanari–Nguyen은 다음 two-layer model을 쓴다.

$$\hat{y}_N(x; \theta) = \frac{1}{N} \sum_{i=1}^N \sigma_*(x; \theta_i), \quad \theta_i \in \mathbb{R}^D.$$

표준적인 경우에는 $\theta_i = (a_i, b_i, w_i)$ 이고

$$\sigma_*(x; \theta_i) = a_i \sigma(\langle w_i, x \rangle + b_i).$$

여기서 $1/N$ 이 중요하다. width가 커져도 각 뉴런의 합이 폭발하지 않도록 output을 평균낸다.

2.2 square loss를 pairwise interaction energy로 전개

population square risk를

$$\mathcal{R}_N(\theta_1, \dots, \theta_N) = \mathbb{E}[(Y - \hat{y}_N(X; \theta))^2]$$

라고 두자. 괄호를 그대로 전개하면

$$\begin{aligned} \mathcal{R}_N &= \mathbb{E}[Y^2] - 2\mathbb{E}\left[Y \frac{1}{N} \sum_{i=1}^N \sigma_*(X; \theta_i)\right] + \mathbb{E}\left[\left(\frac{1}{N} \sum_{i=1}^N \sigma_*(X; \theta_i)\right)^2\right] \\ &= \mathbb{E}[Y^2] - \frac{2}{N} \sum_{i=1}^N \mathbb{E}[Y \sigma_*(X; \theta_i)] \\ &\quad + \frac{1}{N^2} \sum_{i,j=1}^N \mathbb{E}[\sigma_*(X; \theta_i) \sigma_*(X; \theta_j)]. \end{aligned}$$

이제

$$\begin{aligned} R_{\#} &:= \mathbb{E}[Y^2], \\ V(\theta) &:= -\mathbb{E}[Y \sigma_*(X; \theta)], \\ U(\theta, \theta') &:= \mathbb{E}[\sigma_*(X; \theta) \sigma_*(X; \theta')] \end{aligned}$$

라고 정의하면

$$\boxed{\mathcal{R}_N(\theta) = R_{\#} + \frac{2}{N} \sum_{i=1}^N V(\theta_i) + \frac{1}{N^2} \sum_{i,j=1}^N U(\theta_i, \theta_j)} \quad (2.1)$$

이 된다.

원 논문 기준— Mei et al., Eq. (4) 위 식이 원 논문의 finite- N risk 표현이다. U 는 대칭이며 positive semidefinite kernel이다. 이 표현이 중요한 이유는 loss가 각 neuron index의 이름이 아니라 전체 파라미터 분포에만 의존한다는 사실을 드러내기 때문이다.

2.3 왜 이것이 “particle system”인가

θ_i 를 D 차원 공간에서 움직이는 particle의 위치라고 생각한다. 그러면 $V(\theta_i)$ 는 한 particle에 작용하는 외부 potential, $U(\theta_i, \theta_j)$ 는 두 particle 사이의 interaction potential처럼 보인다.

특히 (2.1)은

$$\text{constant} + \text{one-body energy} + \text{pairwise interaction energy}$$

의 형태다. statistical mechanics의 mean-field particle model과 같은 수학 구조가 생긴다.

2.4 finite-width gradient의 크기와 time scaling

U 가 대칭이라고 하자. θ_i 에 대해 미분하면

$$\begin{aligned}\nabla_{\theta_i} \mathcal{R}_N &= \frac{2}{N} \nabla V(\theta_i) + \frac{1}{N^2} \sum_{j=1}^N \nabla_1 U(\theta_i, \theta_j) + \frac{1}{N^2} \sum_{j=1}^N \nabla_2 U(\theta_j, \theta_i) \\ &= \frac{2}{N} \nabla V(\theta_i) + \frac{2}{N^2} \sum_{j=1}^N \nabla_1 U(\theta_i, \theta_j).\end{aligned}$$

따라서 보통의 Euclidean gradient flow

$$\frac{d\theta_i}{ds} = -\nabla_{\theta_i} \mathcal{R}_N$$

는 속도가 $O(1/N)$ 이다. width를 키운 채 같은 s 를 보면 뉴런이 거의 움직이지 않는다.

mean-field dynamics에서는 원래 gradient-flow 시간 s 의 $s = Nt$ 까지를 macroscopic time t 로 묶어 본다. 즉 $t = s/N$ 으로 두면

$$\begin{aligned}\frac{d\theta_i}{dt} &= N \frac{d\theta_i}{ds} \\ &= -2\nabla V(\theta_i) - \frac{2}{N} \sum_{j=1}^N \nabla_1 U(\theta_i, \theta_j).\end{aligned}$$

이제 $N \rightarrow \infty$ 여도 velocity가 $O(1)$ 로 남는다.

주의— “infinite width에서 parameter가 안 움직인다”는 말의 조건 parameter movement는 parameterization과 time/learning-rate scaling에 의존한다. 위 $1/N$ output scaling에서 mean-field time을 쓰면 각 neuron이 $O(1)$ 거리만큼 움직이는 nonlinear feature-learning dynamics가 남는다. width만 보고 lazy 여부를 결정하면 안 된다.

발표에서 이렇게 말하기 두 층 network의 square loss를 전개하면 one-body potential V 와 pair interaction U 의 합이 된다. 그래서 neuron을 particle로 볼 수 있다. 그리고 $1/N$ output scaling에서는 finite-width gradient가 $O(1/N)$ 이므로, mean-field limit을 볼 때는 학습 시간을 그에 맞게 rescale해야 한다.

3

Empirical measure와 infinite-width risk

3.1 순열 대칭을 없애는 empirical measure

network output은 neuron의 순서를 바꿔도 변하지 않는다. 따라서 $(\theta_1, \dots, \theta_N)$ 전체를 상태로 쓰면 같은 network를 $N!$ 번 중복 표현한다.

이를 제거하는 객체가

$$\hat{\rho}_N := \frac{1}{N} \sum_{i=1}^N \delta_{\theta_i} \quad (3.1)$$

이다. 그러면 임의의 test function φ 에 대해

$$\int \varphi(\theta) \hat{\rho}_N(d\theta) = \frac{1}{N} \sum_{i=1}^N \varphi(\theta_i).$$

즉 “뉴런 전체에 대한 평균”은 empirical measure에 대한 적분으로 바뀐다.

3.2 finite risk가 measure functional로 정확히 다시 써진다

(2.1)에 (3.1)를 대입하면

$$\frac{1}{N} \sum_i V(\theta_i) = \int V(\theta) \hat{\rho}_N(d\theta),$$

그리고

$$\frac{1}{N^2} \sum_{i,j} U(\theta_i, \theta_j) = \iint U(\theta, \theta') \hat{\rho}_N(d\theta) \hat{\rho}_N(d\theta').$$

따라서 probability measure ρ 에 대해

$$\mathcal{R}(\rho) = R_{\#} + 2 \int V(\theta) \rho(d\theta) + \iint U(\theta, \theta') \rho(d\theta) \rho(d\theta') \quad (3.2)$$

를 정의하면 정확히

$$\mathcal{R}_N(\theta_1, \dots, \theta_N) = \mathcal{R}(\hat{\rho}_N)$$

이다.

원 논문 기준— Mei et al., Eq. (5) 원문은 $\mathcal{R}$ 대신 R 을 사용한다. 이 식이 “infinite-width objective”다. $N \rightarrow \infty$ 는 단순히 sum을 integral로 바꾸는 것이 아니라, 최적화 변수를 $\mathbb{R}^{ND}$ 의 vector에서 $\mathcal{P}(\mathbb{R}^D)$ 의 probability measure로 바꾼다.

3.3 첫 번째 variation: measure 공간에서의 gradient 역할

Euclidean 함수 $F(x)$ 의 gradient를 만들려면 $F(x + \varepsilon v)$ 를 1차까지 전개한다. measure functional도 똑같이 한다.

총 질량을 보존하는 signed perturbation χ 를 잡아

$$\rho_\varepsilon = \rho + \varepsilon\chi, \quad \chi(\mathbb{R}^D) = 0$$

라고 두자. (3.2)에서

$$\begin{aligned} \mathcal{R}(\rho_\varepsilon) &= R_\# + 2 \int V d(\rho + \varepsilon\chi) \\ &\quad + \iint U(\theta, \theta')(\rho + \varepsilon\chi)(d\theta)(\rho + \varepsilon\chi)(d\theta'). \end{aligned}$$

항별로 전개하면

$$\begin{aligned} \mathcal{R}(\rho_\varepsilon) - \mathcal{R}(\rho) &= 2\varepsilon \int V(\theta)\chi(d\theta) \\ &\quad + 2\varepsilon \iint U(\theta, \theta')\rho(d\theta')\chi(d\theta) \\ &\quad + \varepsilon^2 \iint U(\theta, \theta')\chi(d\theta)\chi(d\theta'). \end{aligned}$$

따라서

$$\Psi(\theta; \rho) := V(\theta) + \int U(\theta, \theta')\rho(d\theta')$$

라고 두면

$$\boxed{\frac{\delta \mathcal{R}}{\delta \rho}(\theta) = 2\Psi(\theta; \rho)} \quad (3.3)$$

이다. probability measure에서는 additive constant가 first variation에 추가되어도 mass-zero perturbation에 대한 directional derivative는 같으므로, 상수까지는 유일하지 않다.

보충 유도 — 논문 밖의 독자용 전개— **functional derivative**의 정의 위 계산은 논문의 notation을 이해하기 위한 보충 전개다. 엄밀히는

$$\left. \frac{d}{d\varepsilon} \mathcal{R}(\rho + \varepsilon\chi) \right|_{\varepsilon=0} = \int \frac{\delta \mathcal{R}}{\delta \rho}(\theta)\chi(d\theta)$$

를 만족시키는 함수를 first variation이라 부른다. 여기서는 그 함수가 2Ψ 다.

3.4 measure에 대해 convex하다는 말

U 가 positive semidefinite kernel이면 $\mathcal{R}$ 는 linear mixture 방향으로 convex하다. $\rho_s = (1-s)\rho_0 + s\rho_1$ 와 $\chi = \rho_1 - \rho_0$ 를 두면

$$\rho_s = \rho_0 + s\chi.$$

$\mathcal{R}(\rho_s)$ 를 s 로 두 번 미분하면

$$\frac{d^2}{ds^2} \mathcal{R}(\rho_s) = 2 \iint U(\theta, \theta')\chi(d\theta)\chi(d\theta') \geq 0.$$

하지만 이 사실만으로 Wasserstein gradient flow의 global convergence가 자동으로 나오지는 않는다. 이 차이는 뒤에서 다시 본다.

발표에서 이렇게 말하기 empirical measure로 loss를 $\mathcal{R}(\rho)$ 로 정확히 쓰면 first variation은 2Ψ 다. 다만 measure-convexity와 Wasserstein geometry는 다르므로, convexity만으로 global convergence를 결론낼 수 없다.

4

Continuity equation과 Wasserstein gradient flow

4.1 움직이는 particle은 어떤 PDE를 만드는가

particle들이 공통 velocity field v_t 를 따라

$$\dot{\theta}_i(t) = v_t(\theta_i(t))$$

로 움직인다고 하자. empirical measure는

$$\hat{\rho}_N(t) = \frac{1}{N} \sum_i \delta_{\theta_i(t)}.$$

smooth test function φ 에 대해

$$\begin{aligned} \frac{d}{dt} \int \varphi(\theta) \hat{\rho}_N(t, d\theta) &= \frac{1}{N} \sum_i \frac{d}{dt} \varphi(\theta_i(t)) \\ &= \frac{1}{N} \sum_i \langle \nabla \varphi(\theta_i(t)), \dot{\theta}_i(t) \rangle \\ &= \int \langle \nabla \varphi(\theta), v_t(\theta) \rangle \hat{\rho}_N(t, d\theta). \end{aligned}$$

integration by parts를 형식적으로 적용하면

$$\int \langle \nabla \varphi, v_t \rangle \rho_t d\theta = - \int \varphi \nabla \cdot (\rho_t v_t) d\theta.$$

따라서 weak sense에서

$$\boxed{\partial_t \rho_t + \nabla \cdot (\rho_t v_t) = 0} \quad (4.1)$$

를 얻는다. 이것이 continuity equation이다.

4.2 mean-field velocity를 넣기

앞 장에서

$$\frac{\delta \mathcal{R}}{\delta \rho} = 2\Psi$$

였다. risk를 가장 빠르게 줄이는 transport velocity는

$$v_t(\theta) = -\xi(t) \nabla_{\theta} \frac{\delta \mathcal{R}}{\delta \rho}(\theta) = -2\xi(t) \nabla_{\theta} \Psi(\theta; \rho_t)$$

로 잡는다.

이를 (4.1)에 넣으면

$$\boxed{\partial_t \rho_t = 2\xi(t) \nabla \cdot (\rho_t \nabla_{\theta} \Psi(\theta; \rho_t))} \quad (4.2)$$

가 나온다.

원 논문 기준— Mei et al., Eq. (7)–(8) 원문의 distributional dynamics(DD)가 정확히 (4.2)다. 여기서 $\xi(t)$ 는 learning-rate schedule의 연속시간 버전이다. 부호를 확인할 때는 continuity equation의 $\partial_t \rho + \nabla \cdot (\rho v) = 0$ 와 $v = -2\xi \nabla \Psi$ 를 함께 기억하면 된다.

4.3 W_2 는 “분포를 옮기는 데 필요한 제공거리”다

$\rho_0, \rho_1 \in \mathcal{P}_2(\mathbb{R}^D)$ 에 대해

$$W_2^2(\rho_0, \rho_1) = \inf_{\gamma \in \Pi(\rho_0, \rho_1)} \iint \|\theta - \theta'\|^2 \gamma(d\theta, d\theta'). \quad (4.3)$$

$\Pi(\rho_0, \rho_1)$ 는 두 marginal이 각각 ρ_0, ρ_1 인 coupling의 집합이다.

Euclidean distance가 한 점을 얼마나 멀리 움직였는지를 재는 것이라면, W_2 는 전체 mass를 얼마나 멀리 운반했는지를 잰다.

4.4 JKO step: Euclidean proximal step의 measure 버전

Euclidean gradient flow $\dot{x} = -\nabla F(x)$ 의 backward-Euler discretization은

$$\frac{x_{k+1} - x_k}{\tau} = -\nabla F(x_{k+1}).$$

이 식은 다음 proximal minimization의 1차 optimality condition과 같다.

$$x_{k+1} = \arg \min_x \left\{ F(x) + \frac{1}{2\tau} \|x - x_k\|^2 \right\}. \quad (4.4)$$

Euclidean squared distance를 W_2^2 로 바꾸면

$$\rho_{t+\tau} \approx \arg \min_{\rho \in \mathcal{P}(\mathbb{R}^D)} \left\{ \mathcal{R}(\rho) + \frac{1}{2\xi(t)\tau} W_2^2(\rho, \rho_t) \right\}. \quad (4.5)$$

원 논문 기준— Mei et al., Eq. (9)–(10) 원문은 W_2 정의를 제시한 직후 (4.5)를 distributional dynamics의 gradient-flow 해석으로 소개한다. 이것은 explicit gradient descent가 아니라 Wasserstein 공간의 **implicit/proximal** time discretization이라는 점에 주의한다.

4.5 risk dissipation을 직접 계산

(4.2)를 따라 $\mathcal{R}(\rho_t)$ 의 시간 미분을 계산한다.

$$\begin{aligned} \frac{d}{dt} \mathcal{R}(\rho_t) &= \int \frac{\delta \mathcal{R}}{\delta \rho}(\theta) \partial_t \rho_t(\theta) d\theta \\ &= \int 2\Psi(\theta; \rho_t) 2\xi(t) \nabla \cdot (\rho_t \nabla \Psi(\theta; \rho_t)) d\theta \\ &= -4\xi(t) \int \rho_t(\theta) \|\nabla \Psi(\theta; \rho_t)\|^2 d\theta \\ &\leq 0. \end{aligned}$$

마지막 줄은 boundary term이 사라진다는 충분한 regularity/decay를 가정한 formal 계산이다.

핵심 Euclidean GF의

$$\frac{d}{dt}F(x(t)) = -\|\nabla F(x(t))\|^2$$

에 대응하여, Wasserstein GF에서는

$$\frac{d}{dt}\mathcal{R}(\rho_t) = -4\xi(t) \int \rho_t \|\nabla \Psi\|^2 \leq 0$$

가 된다. “gradient norm squared”가 particle distribution에 대한 평균으로 바뀐 것이다.

발표에서 이렇게 말하기 particle이 velocity field를 따라 움직이면 empirical density는 continuity equation을 만족한다. 그 velocity를 measure risk의 first variation의 음의 gradient로 잡으면 Mei et al.의 PDE가 나온다. 그래서 이 PDE는 Wasserstein metric에서의 gradient flow이고, Euclidean GF와 마찬가지로 risk가 시간에 따라 감소하는 energy-dissipation identity를 가진다.

5

Mei–Montanari–Nguyen: particle에서 PDE로

5.1 SGD의 scaling

Mei et al.은 one-pass SGD를

$$\theta_i^{k+1} = \theta_i^k + 2s_k(Y_k - \hat{y}_N(X_k; \theta^k)) \nabla_{\theta_i} \sigma_*(X_k; \theta_i^k) \quad (5.1)$$

로 둔다. step size는

$$s_k = \varepsilon \xi(k\varepsilon)$$

이다.

$\hat{y}_N$ 에 $1/N$ 이 있으므로 $\mathcal{R}_N$ 의 진짜 Euclidean gradient는 $O(1/N)$ 이다. 따라서 (5.1)는 finite-dimensional risk에 대한 표준 gradient step을 그대로 쓴 것이라기보다, mean-field time scale을 유지하도록 learning rate를 N 배 rescale한 dynamics로 이해해야 한다.

5.2 limit statement의 구조

iteration k 와 연속시간 t 를

$$t = k\varepsilon$$

로 맞춘다. $k \sim 1/\varepsilon$ 개의 작은 step을 보면서 동시에 $N \rightarrow \infty$ 를 보낸다.

원문의 결론은 개념적으로

$$\hat{\rho}_{[t/\varepsilon]}^{(N)} \Longrightarrow \rho_t \quad (5.2)$$

이며 ρ_t 는 (4.2)의 해다.

원 논문 기준— Mei et al., Theorem 3 가정 A1–A3 아래에서 iid initialization을 사용하고 $N \rightarrow \infty$, $\varepsilon_N \rightarrow 0$ 이 적절히 함께 일어나면 (5.2)가 almost surely 성립한다. 또한 bounded Lipschitz test function과 risk에 대해 finite-time non-asymptotic error bound를 준다. 원문에서 핵심 error scale은

$$\text{err}_{N,D}(z) = (N^{-1/2} \vee \sqrt{\varepsilon}) \left[\sqrt{D + \log(N/\varepsilon)} + z \right]$$

형태로 읽을 수 있으며, bound에는 e^{CT} factor가 붙는다. 정확한 상수와 가정은 Theorem 3을 따른다.

5.3 propagation of chaos는 무엇을 뜻하는가

“chaos”는 dynamics가 혼란스럽다는 뜻이 아니다. 초기 particle들이 iid라면, 상호작용하는 finite- N particle들의 임의의 고정된 유한 부분집합이 $N \rightarrow \infty$ 에서 서로 독립인 nonlinear process처럼 행동한다는 뜻이다.

이를 두 시스템으로 나누어 보면 직관이 명확하다.

상호작용 particle:

$$\dot{\theta}_i^N(t) = -2\xi(t)\nabla\Psi(\theta_i^N(t); \hat{\rho}_N(t)).$$

nonlinear independent copy:

$$\dot{\bar{\theta}}_i(t) = -2\xi(t)\nabla\Psi(\bar{\theta}_i(t); \rho_t), \quad \text{Law}(\bar{\theta}_i(t)) = \rho_t.$$

두 번째 시스템에서는 각 $\bar{\theta}_i$ 가 empirical measure가 아니라 deterministic law ρ_t 를 통해 상호작용하므로, iid initialization이면 서로 iid가 유지된다.

propagation of chaos proof는 대략

$$\theta_i^N(t) \approx \bar{\theta}_i(t)$$

를 uniform finite time에서 보이고, law of large numbers를 결합한다.

보충 유도 — 논문 밖의 독자용 전개 — coupling + Grönwall의 전형적 구조 같은 initialization을 두 시스템에 coupling했다고 하자. Lipschitz drift라면

$$\frac{d}{dt} \|\theta_i^N - \bar{\theta}_i\| \lesssim \|\theta_i^N - \bar{\theta}_i\| + \text{empirical fluctuation},$$

꼴을 얻는다. 이를 적분하고 Grönwall inequality를 쓰면

$$\sup_{s \leq T} \|\theta_i^N(s) - \bar{\theta}_i(s)\| \lesssim e^{CT} \times (\text{finite-}N \text{ fluctuation}).$$

원문의 proof는 SGD discretization error와 finite- N concentration까지 함께 다룬다.

5.4 왜 PDE가 유용한가

finite network에서는 N 개의 neuron label이 모두 남지만, PDE에서는 permutation symmetry가 자동으로 quotient된다. 또한 데이터 분포가 rotation symmetry를 가지면 ρ_t 에도 같은 symmetry를 impose하여 고차원 dynamics를 몇 개의 radial variable로 줄일 수 있다.

Mei et al.의 Gaussian examples가 바로 이 장점을 사용한다. 특정 문제에서는 width N 이 PDE 자체에서 사라지고, convergence time이 N 과 독립적으로 기술된다.

주의 — **theorem**을 과장하지 말 것 Theorem 3은 “모든 wide neural network의 SGD가 이 PDE를 따른다”는 정리가 아니다. 논문은 two-layer model, 특정 scaling, iid initialization, boundedness/Lipschitz 가정, one-pass sampling 등의 조건 아래 limit과 finite-time approximation을 보인다.

발표에서 이렇게 말하기 Mei et al.의 핵심 정리는 “wide network가 그냥 큰 ODE다”에서 끝나지 않는다. $N \rightarrow \infty$ 와 step size $\varepsilon \rightarrow 0$ 를 함께 보내면 empirical parameter distribution이 nonlinear PDE의 해로 수렴한다. proof의 확률론적 이름이 propagation of chaos이고, finite particle과 독립 nonlinear copy를 coupling 한 뒤 concentration과 Grönwall을 쓰는 구조다.

6

Fixed point와 convexity: 왜 아직 문제가 남는가

6.1 risk가 감소한다고 global optimum에 가는 것은 아니다

앞에서

$$\frac{d}{dt}\mathcal{R}(\rho_t) \leq 0$$

를 보였다. 그러나 감소한다는 사실만으로 global minimum convergence는 나오지 않는다.

PDE의 current를

$$J_t(\theta) = -2\xi(t)\rho_t(\theta)\nabla\Psi(\theta; \rho_t)$$

라고 하자. fixed point에서는 mass flow가 없어야 한다.

Mei et al.은 충분한 regularity 아래 fixed point를

$$\text{supp}(\rho) \subseteq \{\theta : \nabla_\theta \Psi(\theta; \rho) = 0\} \quad (6.1)$$

로 characterize 한다.

원 논문 기준— Mei et al., **Proposition 2** V, U 가 differentiable이고 gradient가 bounded 이면 $\mathcal{R}(\rho_t)$ 는 non-increasing이다. 또한 (6.1)가 fixed point의 필요충분조건이다. 원문은 global optimizer는 fixed point지만 fixed point의 집합이 일반적으로 더 크다고 명시한다.

6.2 global optimum의 조건은 더 강하다

measure risk의 first variation이 2Ψ 이므로, probability mass를 어느 위치로 옮겨도 risk를 더 줄일 수 없으려면 support 위의 Ψ 가 전역적으로 최소여야 한다. 원문 Proposition 1의 조건은

$$\text{supp}(\rho_*) \subseteq \arg \min_{\theta \in \mathbb{R}^D} \Psi(\theta; \rho_*)$$

형태다.

fixed point 조건은 support 위에서 $\nabla\Psi = 0$ 만 요구하지만, global optimum 조건은 support가 Ψ 의 global minimizer에 놓이기를 요구한다.

6.3 “measure에 대해 convex”인데 왜 stationary trap이 가능한가

여기가 가장 헷갈리는 부분이다.

1. $\mathcal{R}(\rho)$ 의 convexity는

$$\rho_s = (1-s)\rho_0 + s\rho_1$$

같은 linear interpolation에 대한 convexity다.

2. Wasserstein gradient flow는 mass를 순간이동시키지 않는다. continuity equation을 따라 현재 support에서 velocity field로 mass를 운반한다.
3. 따라서 현재 support의 모든 점에서 $\nabla\Psi = 0$ 이면 transport velocity가 0이 되어 멈출 수 있다. 다른 위치에 더 낮은 Ψ 가 있어도 그곳으로 mass가 teleport되지 않는다.

즉 linear-convexity와 W_2 -geodesic convexity는 다른 개념이다.

보충 유도 — 논문 밖의 독자용 전개 — 두 geometry의 차이를 한 줄로 Euclidean convex optimization에서는 변수 자체가 선형 공간의 점이므로 “convex objective + stationary point”가 global optimum을 준다. 여기서는 objective는 measure의 linear structure에서 convex하지만 dynamics는 transport metric을 따른다. 따라서 필요한 것은 보통 Wasserstein geodesic convexity 또는 dynamics에 맞는 추가 구조다.

6.4 noisy SGD에서는 diffusion이 무엇을 바꾸는가

Mei et al.은 Gaussian noise와 ℓ_2 regularization을 넣은 SGD의 limit으로

$$\partial_t \rho_t = 2\xi(t) \nabla \cdot (\rho_t \nabla \Psi_\lambda(\theta; \rho_t)) + 2\xi(t) \beta^{-1} \Delta \rho_t \quad (6.2)$$

를 얻는다.

diffusion term은 mass가 support 밖으로 퍼질 수 있게 하며, 이에 대응하는 free energy는 risk에 entropy term을 추가한 형태다. Mei et al.의 finite-temperature convergence theorem은 A1–A4와 $1/K_0 \leq \lambda \leq K_0$ 같은 coercive regularization 조건 아래 regularized free energy의 unique minimizer가 존재하고, diffusion PDE가 그 minimizer로 수렴함을 보인다.

주의 noisy SGD의 global convergence 정리를 noiseless PDE에 그대로 옮기면 안 된다. 논문 자체가 noiseless dynamics에는 일반적인 global convergence theorem을 주지 못한다고 구분한다.

발표에서 이렇게 말하기 measure risk가 convex하다는 말만으로 dynamics의 global convergence가 끝나지 않는다. Wasserstein flow는 mass를 실제로 운반해야 하므로 local mass conservation이 있고, $\nabla\Psi = 0$ 인 support에서는 멈출 수 있다. 그래서 Mei et al.은 fixed-point 조건과 global-optimum 조건을 분리하고, noisy case에서는 diffusion과 entropy가 landscape를 더 강하게 regularize한다.

7

Chizat–Bach: optimal transport로 본 global convergence

7.1 조금 더 일반적인 measure optimization

Chizat–Bach은 Hilbert space $\mathcal{F}$ 에서 feature map $\Phi : \Omega \rightarrow \mathcal{F}$ 를 두고

$$F(\mu) = R\left(\int_{\Omega} \Phi(u)\mu(du)\right) + \int_{\Omega} V(u)\mu(du) \quad (7.1)$$

를 최소화한다. R 은 smooth convex loss이고 V 는 regularizer다.

finite particle approximation은

$$\mu_m = \frac{1}{m} \sum_{i=1}^m \delta_{u_i}$$

를 대입한

$$F_m(u_1, \dots, u_m) = F(\mu_m)$$

이다.

7.2 particle gradient flow에서 Wasserstein flow로

논문은 particle flow의 gradient를 m 배 rescale한다. 이는 각 particle의 mass가 $1/m$ 이기 때문에 many-particle limit에서 $O(1)$ velocity를 유지하는 natural metric normalization이다.

smooth case를 단순화해서 쓰면

$$\dot{u}_i(t) = -\nabla_u F'(\mu_{m,t})(u_i(t)), \quad \mu_{m,t} = \frac{1}{m} \sum_i \delta_{u_i(t)}.$$

이에 대응하는 continuum equation은

$$\partial_t \mu_t = -\nabla \cdot (v_t \mu_t), \quad v_t \in -\partial F'(\mu_t). \quad (7.2)$$

원 논문 기준— **Chizat–Bach, Definition 2.4 / Theorem 2.6** Definition 2.4는 (7.2)를 Wasserstein gradient flow로 정의한다. Theorem 2.6은 초기 empirical measures $\mu_{m,0} \rightarrow \mu_0$ in W_2 이면, finite particle gradient flows의 $\mu_{m,t}$ 가 unique Wasserstein gradient flow μ_t 로 수렴한다고 보인다.

7.3 Mei et al.과 무엇이 같은가

두 논문은 notation과 출발점이 다르지만 구조는 같다.

many particles $\longrightarrow$ empirical measure $\longrightarrow$ continuity equation
 $\longrightarrow$ Wasserstein gradient flow.

Mei et al. 은 stochastic SGD와 explicit population square risk에서 PDE approximation을 정량화하는 데 강점이 있고, Chizat–Bach은 measure optimization과 homogeneity를 이용해 global optimality의 구조를 추적한다.

7.4 global convergence는 어떤 추가 구조를 쓰는가

Chizat–Bach의 중요한 메시지는 “ F 가 convex이므로 끝”이 아니다. particle parameterization은 여전히 non-convex이고, Wasserstein stationary point가 자동으로 global optimum도 아니다. 논문은 feature map의 positive homogeneity와 initialization support의 separation condition을 사용한다. 예를 들어 2-homogeneous setting의 Theorem 3.3은 다음 구조다.

원 논문 기준— **Theorem 3.3의 핵심 형태** 기술적 Assumptions 3.2와 support-separation initialization을 만족하는 Wasserstein gradient flow μ_t 가 W_2 에서 μ_∞ 로 수렴한다고 하자. 그러면 μ_∞ 는 F 의 global minimizer다. 또한 suitably initialized particle flows에 대해 many-particle limit과 long-time limit을 결합하여

$$\lim_{m,t \rightarrow \infty} F(\mu_{m,t}) = \min_{\mu \in \mathcal{M}_+(\Omega)} F(\mu)$$

를 얻는다.

여기서 중요한 단어는 “if the flow converges”와 “initialization condition”이다. 정리가 모든 초기화에서 자동 수렴을 보인다고 읽으면 안 된다.

7.5 ReLU에서 homogeneity가 왜 자연스러운가

ReLU는

$$\sigma(cz) = c\sigma(z), \quad c > 0$$

인 1-homogeneous activation이다. output weight까지 함께 scaling하면 한 뉴런 feature는 종종 2-homogeneous parameterization을 갖는다.

예를 들어 bias를 생략하고

$$\Phi(a, w)(x) = a\sigma(\langle w, x \rangle)$$

라 두면 $c > 0$ 에 대해

$$\Phi(ca, cw)(x) = ca\sigma(c\langle w, x \rangle) = c^2 a\sigma(\langle w, x \rangle) = c^2 \Phi(a, w)(x).$$

이 radial scaling 구조가 particle을 새로운 방향으로 “escape”시키는 global-convergence argument에서 중요하게 쓰인다.

주의 NeurIPS 본문의 ReLU discussion은 smoothness 문제 때문에 “formal level”이라는 단서를 둔다. ReLU의 differential discontinuity를 무시한 채 smooth theorem이 그대로 적용된다고 쓰면 부정확하다. 후속/appendix treatment와 regularized parameterization을 함께 봐야 한다.

발표에서 이렇게 말하기 Chizat–Bach은 mean-field PDE를 단지 approximation 도구로 쓰는 데서 한 단계 더 간다. Wasserstein flow가 어떤 조건에서 global minimizer에 도달하는지를 optimal-transport geometry와 homogeneity로 분석한다. 다만 핵심 정리는 convergence와 initialization/support 조건을 가정하므로, “infinite width이면 항상 global optimum”으로 요약하면 안 된다.

8

Infinite width는 하나의 regime이 아니다

8.1 mean-field와 lazy training의 차이

두-layer model을 추상적으로

$$h_m(w) = \alpha(m) \sum_{i=1}^m \phi(\theta_i) \quad (8.1)$$

라고 쓰자. width를 $m \rightarrow \infty$ 로 보내도 $\alpha(m)$ 을 어떻게 잡는지에 따라 dynamics가 달라진다.

Chizat–Oyallon–Bach은 iid initialization과 centering 조건 아래, lazy-training indicator가 대략

$$\mathbb{E}[\kappa_{h_m}(w_0)] \lesssim m^{-1/2} + (m\alpha(m))^{-1} \quad (8.2)$$

로 제어된다고 설명한다.

따라서 $m\alpha(m) \rightarrow \infty$ 이면 width가 커질수록 lazy regime으로 가는 경향이 있다. 반대로

$$\boxed{\alpha(m) = 1/m}$$

은 $m\alpha(m) = 1$ 이므로 이 criterion으로 lazy가 강제되지 않는 critical scaling이며, 논문은 이것을 non-degenerate PDE로 이어지는 mean-field scaling으로 지목한다.

원 논문 기준— **Chizat–Oyallon–Bach, Sec. 1.2** 원문은 two-layer model에서 $\alpha(m) = 1/m$ 을 mean-field limit의 critical scaling으로 설명하고, $m\alpha(m) \rightarrow \infty$ 인 scaling은 large width에서 lazy behavior로 향할 수 있음을 구분한다.

8.2 lazy training은 정확히 무엇인가

smooth model $h(w)$ 를 initialization w_0 에서 선형화하면

$$\bar{h}(w) = h(w_0) + Dh(w_0)(w - w_0).$$

lazy regime은 nonlinear training path가 이 linearized model의 training path와 끝까지 가깝게 유지되는 경우다.

scaled objective를

$$F_\alpha(w) = \frac{1}{\alpha^2} R(\alpha h(w))$$

라고 두면, $h(w_0) = 0$ 일 때 Theorem 2.2는 fixed time horizon T 에 대해

$$\begin{aligned} \sup_{t \leq T} \|w_\alpha(t) - w_0\| &= O(1/\alpha), \\ \sup_{t \leq T} \|w_\alpha(t) - \bar{w}_\alpha(t)\| &= O(1/\alpha^2), \\ \sup_{t \leq T} \|\alpha h(w_\alpha(t)) - \alpha \bar{h}(\bar{w}_\alpha(t))\| &= O(1/\alpha) \end{aligned}$$

를 준다.

parameter movement가 작으므로 Jacobian $Dh(w)$ 가 거의 고정되고, 결과적으로 kernel-like dynamics가 나타난다.

8.3 표로 정리하는 두 regime

	Mean-field regime	Lazy / linearized regime
대표 output scaling	$1/m$	예: $1/\sqrt{m}$ 계열 또는 large explicit scale
개별 뉴런 이동 feature 변화 limit state	적절한 time scale에서 $O(1)$ 가능 지속적으로 가능 parameter distribution ρ_t	작음 initialization feature에 가까움 tangent / kernel dynamics
주요 수학	nonlinear PDE, W_2 GF	linearization, tangent kernel
“infinite width”의 역할	particle law를 deterministic화	Jacobian/kernel을 고정시키는 limit 가능

주의— $1/\sqrt{m}$ 을 무조건 NTK scaling이라고 부르지 말 것. 정확한 scaling은 architecture, parameterization, learning-rate normalization에 따라 달라진다. 위 표는 two-layer centered model의 전형적 대비를 보여주는 것이다. “ $1/m = \text{mean-field}$, $1/\sqrt{m} = \text{NTK}$ ”를 모든 network에 적용하는 규칙으로 외우지 않는다.

8.4 다음 주 NTK와의 연결

mean-field에서는 state가 ρ_t 자체이므로 feature distribution이 시간에 따라 바뀐다. 반면 lazy regime에서는

$$h(w) \approx h(w_0) + Dh(w_0)(w - w_0)$$

이므로 학습을 지배하는 operator가 initialization의 Jacobian으로 고정된다.

다음 주 NTK에서는 이 Jacobian이 만드는 kernel

$$K_0(x, x') = \langle \nabla_w f(w_0, x), \nabla_w f(w_0, x') \rangle$$

이 infinite-width limit에서 deterministic해지고, 함수 dynamics가 kernel gradient flow로 닫히는 과정을 본격적으로 다룬다.

핵심 Infinite width는 결론이 아니라 limit를 취하는 축이다. 어떤 parameterization과 learning-rate/time scaling을 함께 택하느냐에 따라 nonlinear mean-field feature learning도, lazy kernel dynamics도 나올 수 있다.

발표에서 이렇게 말하기 “무한 폭이면 NTK”라고 말하면 이번 주와 다음 주를 구분할 수 없다. $1/m$ critical scaling에서는 neuron distribution이 실제로 움직이는 nonlinear mean-field PDE가 남는다. 반대로 scale이 커져 parameter displacement가 작아지면 model이 initialization의 linearization처럼 움직여 lazy/kernel regime이 된다. width가 아니라 scaling까지 함께 지정해야 dynamics가 정해진다.

9

발표 준비용 압축 정리

9.1 칠판에 반드시 남길 여섯 식

1. Two-layer network

$$f_N(x) = \frac{1}{N} \sum_{i=1}^N \sigma_*(x; \theta_i).$$

2. Empirical measure

$$\hat{\rho}_N = \frac{1}{N} \sum_{i=1}^N \delta_{\theta_i}.$$

3. Measure risk

$$\mathcal{R}(\rho) = R_{\#} + 2 \int V \, d\rho + \iint U \, d\rho \, d\rho.$$

4. First variation

$$\frac{\delta \mathcal{R}}{\delta \rho}(\theta) = 2\Psi(\theta; \rho), \quad \Psi(\theta; \rho) = V(\theta) + \int U(\theta, \theta') \rho(d\theta').$$

5. Mean-field PDE

$$\partial_t \rho_t = 2\xi(t) \nabla \cdot (\rho_t \nabla \Psi).$$

6. Energy dissipation

$$\frac{d}{dt} \mathcal{R}(\rho_t) = -4\xi(t) \int \rho_t \|\nabla \Psi\|^2 \leq 0.$$

9.2 발표 순서 추천

1. **Motivation:** N 개 neuron ODE를 계속 추적하는 대신 distribution을 추적하자.
2. **Exact algebra:** square loss를 V, U 로 전개하고 empirical measure로 rewrite 한다.
3. **Geometry:** particle velocity $\Rightarrow$ continuity equation $\Rightarrow W_2$ gradient flow.
4. **Theorem:** Mei et al.의 propagation-of-chaos / particle-to-PDE result.
5. **Subtlety:** risk의 linear convexity와 Wasserstein stationary point는 같은 말이 아니다.
6. **Global convergence:** Chizat–Bach의 homogeneity + initialization 조건.
7. **Bridge:** infinite width에는 mean-field와 lazy regime이 모두 있으며 scaling이 둘을 가른다.

9.3 자주 나오는 질문

Q1. ρ 는 실제로 학습하는 parameter인가?

finite network에서는 직접 학습하는 것은 θ_i 들이다. ρ_t 는 이들의 empirical distribution의 large-width limit이다. continuum formulation에서는 ρ 자체를 optimization variable로 본다.

Q2. 왜 ordinary L^2 gradient flow가 아니라 Wasserstein gradient flow인가?

probability mass가 생성/소멸하는 것이 아니라 particle의 이동으로 바뀌기 때문이다. continuity equation이 local mass conservation을 강제하고, 그 transport cost가 W_2 geometry를 만든다.

Q3. measure risk가 convex인데 왜 non-convex optimization을 해결했다고 바로 말하지 못하나?

convexity는 linear interpolation에 대한 것이고 dynamics는 Wasserstein transport를 따른다. W_2 stationary-point 집합은 global-minimizer 집합보다 클 수 있다.

Q4. propagation of chaos가 independent particle이라는 뜻이면 interaction은 사라지는가?

개별 pairwise randomness는 사라지지만 interaction은 law ρ_t 를 통해 남는다. 그래서 limit ODE/PDE는 여전히 nonlinear하다.

Q5. infinite width와 NTK는 같은가?

아니다. width limit과 함께 어떤 output/learning-rate scaling을 취하는지가 중요하다. mean-field scaling에서는 ρ_t 가 크게 움직일 수 있고, lazy scaling에서는 linearization이 유지된다.

9.4 혼한 수학적 실수 체크리스트

- $\delta\mathcal{R}/\delta\rho = \Psi$ 라고 써 factor 2를 잃지 않았는가?
- continuity equation의 부호와 velocity의 부호를 동시에 확인했는가?
- Mei PDE의 factor $2\xi(t)$ 를 빠뜨리지 않았는가?
- $\mathcal{R}(\rho)$ 의 linear convexity를 W_2 geodesic convexity라고 부르지 않았는가?
- Theorem 3의 finite-time approximation을 infinite-time convergence로 바꾸지 않았는가?
- Chizat-Bach의 theorem에서 convergence/initialization/homogeneity 가정을 생략하지 않았는가?
- $1/\sqrt{m}$ vs $1/m$ 구분을 architecture-independent 법칙처럼 말하지 않았는가?
- “propagation of chaos”를 chaotic dynamics라는 의미로 설명하지 않았는가?

9.5 30초 결론

finite-width two-layer network는 neuron parameter라는 particle들의 상호작용계로 볼 수 있다. empirical measure를 상태로 바꾸고 width를 키우면 particle dynamics가 nonlinear continuity PDE로 수렴한다. 그 PDE는 parameter distribution의 risk를 줄이는 Wasserstein gradient flow이며, propagation of chaos가 finite network와 continuum dynamics를 연결한다. 다만 infinite width만으로 dynamics가 하나로 정해지지는 않는다. $1/m$ mean-field scaling에서는 feature distribution이 움직이고, lazy scaling에서는 initialization 주변 선형화가 남는다.

발표에서 이렇게 말하기 발표 전체를 한 문장으로 줄이면 이렇다. “Wide network의 학습을 뉴런 하나 하나의 좌표가 아니라 뉴런 분포의 이동으로 보면, SGD가 Wasserstein gradient flow PDE로 바뀌고, scaling에 따라 feature-learning mean-field regime과 lazy/kernel regime이 갈린다.”

참고문헌 및 원문에서 확인할 위치

Song Mei, Andrea Montanari, Phan-Minh Nguyen. “A Mean Field View of the Landscape of Two-Layer Neural Networks.” PNAS 115(33), 2018; extended version arXiv:1804.06561.

- Sec. 1.1, Eq. (4)–(10): finite risk, measure risk, DD PDE, W_2 , JKO interpretation.
- Sec. 3, Theorem 3: SGD $\rightarrow$ PDE / propagation of chaos and finite-time error.
- Sec. 3, Proposition 2: risk monotonicity and fixed-point characterization.
- Sec. 3.1: noisy SGD, diffusion PDE, free-energy dissipation.

<https://arxiv.org/abs/1804.06561>

Lénaïc Chizat, Francis Bach. “On the Global Convergence of Gradient Descent for Over-parameterized Models using Optimal Transport.” NeurIPS 2018.

- Sec. 2.2–2.4: particle gradient flow, Wasserstein gradient flow, many-particle limit.
- Theorem 2.6: empirical particle flows $\rightarrow$ unique Wasserstein flow.
- Theorem 3.3 and 3.5: homogeneity/separation assumptions and asymptotic global optimality.
- Sec. 4.2: single-hidden-layer neural-network specialization and ReLU smoothness caveat.

<https://proceedings.neurips.cc/paper/2018/hash/a1afc58c6ca9540d057299ec3016d726-Abstract.html>

Lénaïc Chizat, Édouard Oyallon, Francis Bach. “On Lazy Training in Differentiable Programming.” NeurIPS 2019.

- Sec. 1.1–1.2: lazy training definition, scale criterion, two-layer scaling discussion.
- Sec. 1.2: $\alpha(m) = 1/m$ as the critical mean-field scaling in the model considered there.
- Theorem 2.2: finite-horizon closeness to the linearized model for large scale α .

<https://papers.nips.cc/paper/8559-on-lazy-training-in-differentiable-programming>

주의— 원문과 이 노트의 경계 functional derivative 전개, continuity equation의 test-function derivation, energy-dissipation 계산, convexity와 transport geometry의 비교, propagation-of-chaos의 coupling 스케치는 발표 준비를 위해 추가한 보충 유도다. 원 논문의 정리 statement와 proof 전체를 재현한 것은 아니며, 정리 적용 시에는 위에 적은 원문 section의 가정을 다시 확인해야 한다.