

Neural Tangent Kernel, Lazy Training, and Feature Learning

발표 준비용 수학 노트

이 노트의 목표는 NTK를 단순한 “무한폭 커널”로 외우는 것이 아니라, parameter gradient flow에서 function-space dynamics가 어떻게 나오고, 어떤 scaling에서 그 dynamics가 고정 커널로 닫히는지를 수식으로 이해하는 것이다. 마지막에는 같은 infinite-width limit에서도 feature learning이 살아남을 수 있다는 mean-field 및 μP 관점과 비교한다.

Primary readings

Jacot, Gabriel, Hongler, **Neural Tangent Kernel**, NeurIPS 2018.

Lee et al., **Wide Neural Networks of Any Depth Evolve as Linear Models Under Gradient Descent**, NeurIPS 2019.

Chizat, Oyallon, Bach, **On Lazy Training in Differentiable Programming**, NeurIPS 2019.

Yang, Hu, **Tensor Programs IV: Feature Learning in Infinite-Width Neural Networks**, ICML 2021.

Contents

1	기호와 이번 주의 핵심 질문	2
1.1	기호 대응표	2
1.2	이번 주의 질문	2
2	Parameter gradient flow에서 NTK로	3
2.1	Function-space dynamics	3
2.2	Kernel이 고정되어 있다면	3
2.3	일반 loss	3
3	Jacot et al.: infinite-width NTK	5
3.1	초기화에서의 kernel limit	5
3.2	학습 중 kernel constancy	5
4	Linearization과 kernel regression	6
4.1	초기점에서의 1차 Taylor model	6
4.2	Minimum-norm solution	6
4.3	Lee et al.: wide network는 linearization을 따른다	6
5	Lazy training의 정확한 의미	7
5.1	작은 parameter displacement	7
5.2	Scaling이 laziness를 강제할 수 있다	7
5.3	Lazy는 느리다는 뜻이 아니다	7
6	Feature learning과 scaling dichotomy	8
6.1	Mean-field scaling과 NTK scaling	8
6.2	Yang-Hu: infinite width에서도 feature learning은 가능하다	8
6.3	μP 의 의미	8
7	Regime을 어떻게 비교할 것인가	9
7.1	한눈에 보는 비교	9
7.2	실험에서의 진단	9
7.3	NTK theory가 말하지 않는 것	9
8	발표용 체크리스트	10
8.1	반드시 남길 식 8개	10
8.2	자주 나오는 오류	10
	Bibliography	11

1

기호와 이번 주의 핵심 질문

1.1 기호 대응표

신경망을 $f_\theta(x)$, 파라미터를 $\theta \in \mathbb{R}^p$, 학습 입력을 $X = (x_1, \dots, x_n)$ 라 하자. 학습점에서의 출력 벡터와 Jacobian은

$$f_\theta(X) = [f_\theta(x_1) \ \cdots \ f_\theta(x_n)]^\top, \quad J_\theta(X) = \frac{\partial f_\theta(X)}{\partial \theta}$$

이다. empirical neural tangent kernel은

$$K_\theta(X, X) = J_\theta(X) J_\theta(X)^\top$$

이고, square loss에서는 residual을 $r_\theta = f_\theta(X) - y$ 로 둔다.

개념	Jacot et al.	Lee et al.	Chizat et al.
network	f_θ	$f(\theta, x)$	$h(w)$ / scaled model
tangent kernel	Θ_∞	$\hat{\Theta}_t$	tangent model
linearization	kernel limit에 내재	Taylor model로 명시	lazy regime
feature learning	strict NTK limit에서 소멸	linearization 이탈	non-lazy regime

1.2 이번 주의 질문

Mean-field theory에서는 폭이 무한대로 가더라도 neuron distribution이 움직이면서 feature learning이 남을 수 있었다. NTK theory는 다른 limit을 묻는다. 폭이 충분히 클 때 학습 경로가 초기점 근처에 머물러, 신경망 전체의 학습이 초기점에서의 1차 Taylor 근사로 설명될 수 있는가?

중요한 점은

$$\text{width } m \rightarrow \infty \not\Rightarrow \text{하나의 유일한 dynamics}$$

라는 것이다. parameterization, output scaling, learning rate, initialization이 함께 kernel-like regime인지 feature-learning regime인지를 결정한다.

발표에서 이렇게 말하기 NTK는 임의로 정의한 similarity measure가 아니다. 파라미터 공간의 gradient flow를 network Jacobian을 통해 함수 공간으로 옮기면 정확히 등장하는 Gram matrix이다.

2

Parameter gradient flow에서 NTK로

2.1 Function-space dynamics

Square loss를

$$\mathcal{L}(\theta) = \frac{1}{2} \|f_\theta(X) - y\|^2 = \frac{1}{2} \|r_\theta\|^2$$

라 하자. parameter gradient flow는

$$\dot{\theta}_t = -\nabla_\theta \mathcal{L}(\theta_t)$$

이다. chain rule에 의해

$$\nabla_\theta \mathcal{L}(\theta_t) = J_t^\top r_t$$

이므로

$$\dot{\theta}_t = -J_t^\top r_t.$$

이제 prediction을 시간으로 미분하면

$$\begin{aligned} \frac{d}{dt} f_{\theta_t}(X) &= J_t \dot{\theta}_t \\ &= -J_t J_t^\top r_t \\ &= -K_t r_t. \end{aligned}$$

y 는 고정이므로

$$\boxed{\dot{r}_t = -K_t r_t.}$$

이 식은 infinite width를 쓰지 않았다. 미분 가능한 모든 신경망에서 parameter gradient flow에 대해 정확한 항등식이다.

2.2 Kernel이 고정되어 있다면

만약 $K_t \equiv K_0$ 라면

$$\dot{r}_t = -K_0 r_t$$

이고, 따라서

$$\boxed{r_t = e^{-K_0 t} r_0.}$$

$K_0 = Q\Lambda Q^\top$ 라 두면 각 eigenmode는 $e^{-\lambda_i t}$ 로 감소한다. 즉 kernel spectrum이 optimization의 time scale을 결정한다.

2.3 일반 loss

일반적인 loss $\ell(f(X), y)$ 에 대해서는

$$\dot{f}_t(X) = -K_t \nabla_f \ell(f_t(X), y)$$

이다. NTK는 function space에서 data-dependent preconditioner처럼 작동한다고 볼 수 있다.

발표에서 이렇게 말하기 먼저 유한 폭에서 정확한 식 $\dot{f} = -K_t \nabla_f \ell$ 를 유도하고, 그 다음 infinite-width theorem을 소개하는 것이 좋다. 무한폭 정리는 특정 scaling에서 K_t 가 deterministic kernel로 수렴하고 학습 중 거의 변하지 않는다는 추가 주장이다.

3

Jacot et al.: infinite-width NTK

3.1 초기화에서의 kernel limit

Fully connected network를 표준적인 독립 초기화로 두면, layerwise covariance가 deterministic recursion으로 수렴한다. 개략적으로

$$\Sigma^{(0)}(x, x') = \frac{1}{d} x^\top x'$$

이고, (u, v) 가 $\Sigma^{(\ell)}$ 로 정해지는 joint Gaussian이면

$$\Sigma^{(\ell+1)}(x, x') = \mathbb{E}[\sigma(u)\sigma(v)].$$

미분 activation에 대한 covariance는

$$\dot{\Sigma}^{(\ell+1)}(x, x') = \mathbb{E}[\sigma'(u)\sigma'(v)]$$

이다. 표준 fully connected parameterization에서 limiting NTK는 대략

$$\Theta^{(\ell+1)} = \Sigma^{(\ell+1)} + \Theta^{(\ell)} \dot{\Sigma}^{(\ell+1)}$$

형태의 recursion을 따른다. 정확한 base case와 상수는 parameterization convention에 따라 달라진다.

3.2 학습 중 kernel constancy

NTK parameterization에서는 충분히 넓은 network가 $O(1)$ training time 동안 파라미터 공간에서 매우 짧은 거리만 이동한다. 정리의 가정 아래에서 폭이 무한대로 가면 finite time interval에서

$$K_t \longrightarrow \Theta_\infty$$

가 성립하고, dynamics는

$$\dot{f}_t(X) = -\Theta_\infty \nabla_f \ell(f_t(X), y)$$

로 닫힌다. square loss에서는 선형 ODE가 된다.

주의 “NTK가 고정된다”는 말은 특정 scaling에서의 infinite-width statement다. finite-width network에서는 일반적으로 $K_t \neq K_0$ 이며, 오히려 $\|K_t - K_0\|$ 의 크기가 feature learning을 측정하는 하나의 진단값이 된다.

발표에서 이렇게 말하기 Jacot et al.의 핵심은 forward map 자체가 선형이라는 것이 아니다. 신경망의 출력 함수는 여전히 비선형이지만, 학습 dynamics가 초기점의 tangent kernel에 의해 거의 선형화된다는 것이다.

4

Linearization과 kernel regression

4.1 초기점에서의 1차 Taylor model

초기점 θ_0 주변에서

$$f_{\text{lin}}(x; \theta) = f_{\theta_0}(x) + J_0(x)(\theta - \theta_0)$$

로 선형화하자. 이 linear model을 gradient flow로 학습하면 고정 kernel K_0 를 사용하는 동일한 function-space equation을 얻는다.

4.2 Minimum-norm solution

Linearized model이 training set을 interpolation한다고 하자. $\Delta\theta = \theta - \theta_0$ 라 두면

$$J_0\Delta\theta = y - f_0(X)$$

를 풀어야 한다. $\Delta\theta = 0$ 에서 시작한 gradient flow는 최소 Euclidean norm 해

$$\Delta\theta_\star = J_0^\top (J_0 J_0^\top)^+ (y - f_0(X))$$

를 선택한다. test point x 에서는

$$\begin{aligned} f_\star(x) &= f_0(x) + J_0(x)\Delta\theta_\star \\ &= f_0(x) + K_0(x, X)K_0(X, X)^+(y - f_0(X)). \end{aligned}$$

이는 empirical NTK를 사용하는 ridgeless kernel regression predictor와 동일하다.

4.3 Lee et al.: wide network는 linearization을 따른다

Lee et al.은 이 linearization 관점을 명시적으로 정리한다. 적절한 parameterization, width, learning-rate, time 조건 아래에서 실제 wide network의 출력은 초기점에서의 1차 Taylor model 출력과 가깝게 유지된다. 따라서 비선형 parameter dynamics 전체를 직접 풀지 않고도 kernel dynamics로 optimization과 prediction을 근사할 수 있다.

발표에서 이렇게 말하기 NTK와 kernel regression의 연결은 비유가 아니다. 초기 Jacobian $J_0(x)$ 가 linearized model의 feature이고, 그 Gram matrix가 정확히 $J_0 J_0^\top = K_0$ 이다.

5

Lazy training의 정확한 의미

5.1 작은 parameter displacement

미분 가능한 모델 $h(w)$ 가 학습 경로 전체에서

$$h(w) \approx h(w_0) + Dh(w_0)(w - w_0)$$

로 충분히 잘 근사되면 lazy regime이라고 부른다. Chizat–Oyallon–Bach의 관점에서는 초기 오차, 2차 미분, 1차 미분의 상대 크기를 비교하는 무차원량을 생각할 수 있다:

$$\kappa_h(w_0) \sim \|h(w_0) - y^*\| \frac{\|D^2h(w_0)\|}{\|Dh(w_0)\|^2}.$$

이 값이 작다면 target을 맞추는 데 필요한 parameter movement가 작아, parameter-to-output map의 curvature가 leading order에서 중요하지 않다.

5.2 Scaling이 laziness를 강제할 수 있다

모델 출력의 parameter sensitivity가 scale parameter α 에 따라 커진다고 하자. 그러면 $O(1)$ 크기의 출력 변화를 만들기 위해 필요한 parameter displacement는 $O(1/\alpha)$ 까지 작아질 수 있다. 따라서 $\alpha \rightarrow \infty$ 로 보내면 architecture를 바꾸지 않고도 tangent approximation에 갇힌 regime을 만들 수 있다.

5.3 Lazy는 느리다는 뜻이 아니다

“lazy”는 optimization speed가 아니라 feature movement를 뜻한다. kernel eigenvalue가 충분히 크면 매우 빠르게 loss를 줄이면서도 내부 representation은 거의 변하지 않을 수 있다.

발표에서 이렇게 말하기 Lazy training은 기하학적으로 정의하는 편이 가장 명확하다. 학습 경로가 충분히 짧아 tangent feature가 거의 변하지 않는 regime이다. 단순히 “wide”, “small learning rate”, “slow training”과 동의어가 아니다.

6

Feature learning과 scaling dichotomy

6.1 Mean-field scaling과 NTK scaling

개략적인 two-layer network를

$$f_m(x) = \alpha_m \sum_{i=1}^m a_i \sigma(w_i^\top x)$$

라 하자. $\alpha_m \propto m^{-1/2}$ 와 $\alpha_m \propto m^{-1}$ 같은 scaling은 output magnitude와 parameter movement 사이의 균형을 다르게 만든다. kernel-like scaling에서는 많은 neuron이 아주 조금씩 움직여도 $O(1)$ 출력 변화가 만들어진다. 반면 mean-field scaling에서는 각 neuron이 $O(1)$ 만큼 이동할 수 있고, neuron distribution 자체가 시간에 따라 변한다.

6.2 Yang-Hu: infinite width에서도 feature learning은 가능하다

Tensor-program 분석은 이 scaling 문제를 체계화한다. 넓은 architecture class에서 stable parameterization을 택하면 infinite-width limit가 kernel-like regime으로 갈 수도 있고, genuine feature-learning regime으로 갈 수도 있다. 핵심은 feature learning을 유지하려면 layer별 update가 내부 representation을 $O(1)$ scale로 바꿀 수 있도록 scaling을 맞춰야 한다는 것이다.

6.3 μP 의 의미

Maximal Update Parameterization (μP)는 width가 바뀌어도 layerwise update가 안정적이면서 비자명하게 유지되도록 parameter 및 learning-rate scaling을 정한다. 목표는 폭을 키웠을 때 fixed-kernel dynamics로 붕괴하지 않고 feature-learning behavior를 유지하는 것이다.

주의 Kernel regime과 feature-learning regime의 구분을 성능의 우열로 읽으면 안 된다. kernel limit는 분석하기 쉽고 실제로 강한 predictor가 될 수 있다. 이론이 구분하는 것은 representation이 leading order에서 바뀔 수 있는지 여부다.

발표에서 이렇게 말하기 중요한 축은 finite width 대 infinite width가 아니다. frozen tangent feature 대 evolving feature이다. scaling에 따라 두 behavior 모두 infinite-width limit에서 나타날 수 있다.

7

Regime을 어떻게 비교할 것인가

7.1 한눈에 보는 비교

	NTK / lazy	Mean-field	Finite feature learning
parameter movement	vanishing / small	rescaling 후 $O(1)$	architecture dependent
kernel evolution	limit에서 소멸	일반적으로 비자명	직접 측정 가능
representation	사실상 고정	distribution이 진화	진화
limit equation	kernel ODE	transport PDE	nonlinear SGD/GD
주요 도구	RKHS, spectrum	Wasserstein, PDE	nonlinear optimization

7.2 실험에서의 진단

실제로는 다음을 함께 보는 것이 좋다.

- $\|K_t - K_0\|$ 가 얼마나 변하는가?
- parameter가 initialization에서 상대적으로 얼마나 멀리 이동하는가?
- hidden representation이 새로운 task structure에 맞게 바뀌는가?
- frozen-feature 또는 kernel baseline이 실제 학습된 network와 비슷한 성능을 내는가?

어느 하나가 보편적인 정의는 아니지만, 여러 진단을 함께 쓰면 regime 차이를 비교할 수 있다.

7.3 NTK theory가 말하지 않는 것

NTK convergence theorem은 realistic finite width에서 SGD가 반드시 동일한 solution을 찾는다고 말하지 않는다. 실제 network에서 feature learning이 없다고도 말하지 않으며, kernel predictor와 finite network가 동일한 out-of-distribution behavior를 가진다는 보장도 아니다.

발표에서 이렇게 말하기 NTK theory를 “controlled linearization theorem”으로 설명하면 가장 깔끔하다. 강점은 training을 고정 커널 dynamics로 바꾼다는 것이고, 한계도 같은 지점에서 온다. learned representation의 변화가 1차 근사에서는 사라진다.

8

발표용 체크리스트

8.1 반드시 남길 식 8개

$$\begin{aligned}
\dot{\theta} &= -J^\top r, \\
K_\theta &= JJ^\top, \\
\dot{r} &= -K_t r, \\
r_t &= e^{-K_0 t} r_0 \quad (K_t = K_0), \\
f_{\text{lin}}(x) &= f_0(x) + J_0(x)(\theta - \theta_0), \\
f_\star(x) &= f_0(x) + K_0(x, X)K_0(X, X)^+(y - f_0(X)), \\
\Theta^{(\ell+1)} &= \Sigma^{(\ell+1)} + \Theta^{(\ell)}\dot{\Sigma}^{(\ell+1)}, \\
\rho_t &\text{는 mean-field regime에서 비자명하게 진화한다.}
\end{aligned}$$

8.2 자주 나오는 오류

- $K = JJ^\top$ 자체가 infinite-width result 라고 말하는 것. 이 항등식은 finite width에서도 정확하다.
- neural-network training 동안 kernel이 항상 고정된다고 말하는 것.
- infinite width를 하나의 유일한 kernel limit와 동일시하는 것.
- 작은 parameter displacement와 작은 function change를 혼동하는 것.
- representational theorem을 “SGD가 반드시 그렇게 학습한다”는 주장으로 읽는 것.

발표에서 이렇게 말하기 30초 결론은 다음과 같다. parameter gradient flow를 Jacobian을 통해 함수 공간으로 옮기면 NTK가 정확히 등장한다. 한 종류의 infinite-width scaling에서는 kernel이 freeze되어 network가 linearization을 따르지만, mean-field나 μP 계열 scaling에서는 feature가 leading order에서 계속 움직일 수 있다.

Bibliography

- Jacot, A., Gabriel, F., and Hongler, C. *Neural Tangent Kernel: Convergence and Generalization in Neural Networks*. NeurIPS, 2018.
- Lee, J. et al. *Wide Neural Networks of Any Depth Evolve as Linear Models Under Gradient Descent*. NeurIPS, 2019.
- Chizat, L., Oyallon, E., and Bach, F. *On Lazy Training in Differentiable Programming*. NeurIPS, 2019.
- Yang, G. and Hu, E. J. *Tensor Programs IV: Feature Learning in Infinite-Width Neural Networks*. ICML, 2021.